Haciendo Big Data a League of Legends

Jorge de Andrés

16 de enero de 2019

Limpiamos environment:

```
rm(list=ls())
```

Importamos los paquetes necesarios:

```
#install.packages("knitr")
#install.packages("dplyr")
#install.packages("pryr")
#install.packages("corrplot")
#install.packages("rjson")
#install.packages("plyr")
#install.packages("wordcloud")
#install.packages("ggplot2")
#install.packages("hexbin")
#install.packages("RColorBrewer")
#install.packages("FactoMineR")
#devtools::install_github("kassambara/factoextra")
#install.packages("factoextra")
#install.packages("arules")
#install.packages("arulesViz")
#install.packages("fastDummies")
#install.packages("caret")
#install.packages("nnet")
#install.packages("gmodels")
#install.packages("class")
#install.packages("randomforest")
#install.packages("e1071")
#install.packages("aplpack")
#install.packages("cluster")
#install.packages("fpc")
#install.packages("purrr")
#install.packages("RWeka")

library("corrplot")

## corrplot 0.84 loaded

library("dplyr")

##
## Attaching package: 'dplyr'
```

```
## The following objects are masked from 'package:stats':
##
##     filter, lag

## The following objects are masked from 'package:base':
##
##     intersect, setdiff, setequal, union

library("pryr")
library("rjson")
library("plyr")

## ------------------------------------------------------------------------
---

## You have loaded plyr after dplyr - this is likely to cause problems.
## If you need functions from both plyr and dplyr, please load plyr
first, then dplyr:
## library(plyr); library(dplyr)

## ------------------------------------------------------------------------
---

##
## Attaching package: 'plyr'

## The following objects are masked from 'package:dplyr':
##
##     arrange, count, desc, failwith, id, mutate, rename, summarise,
##     summarize

library("wordcloud")

## Loading required package: RColorBrewer

library("ggplot2")
library("hexbin")
library("RColorBrewer")
library("FactoMineR")
library("factoextra")

## Welcome! Related Books: `Practical Guide To Cluster Analysis in R` at
https://goo.gl/13EFCZ

require("arulesViz")

## Loading required package: arulesViz

## Loading required package: arules

## Loading required package: Matrix

##
## Attaching package: 'arules'
```

```
## The following object is masked from 'package:pryr':
##
##     inspect

## The following object is masked from 'package:dplyr':
##
##     recode

## The following objects are masked from 'package:base':
##
##     abbreviate, write

## Loading required package: grid

require("arules")
library("Matrix")
library("fastDummies")
library("caret")

## Loading required package: lattice

library("nnet")
library("gmodels")
library("class")
library("randomForest")

## randomForest 4.6-14

## Type rfNews() to see new features/changes/bug fixes.

##
## Attaching package: 'randomForest'

## The following object is masked from 'package:ggplot2':
##
##     margin

## The following object is masked from 'package:dplyr':
##
##     combine

library("e1071")
library("aplpack")

## Loading required package: tcltk

library("cluster")
library("fpc")
library("purrr")

##
## Attaching package: 'purrr'
```

```
## The following object is masked from 'package:caret':
##
##     lift

## The following object is masked from 'package:plyr':
##
##     compact

## The following objects are masked from 'package:pryr':
##
##     compose, partial

library("RWeka")
library("data.table")

##
## Attaching package: 'data.table'

## The following object is masked from 'package:purrr':
##
##     transpose

## The following object is masked from 'package:pryr':
##
##     address

## The following objects are masked from 'package:dplyr':
##
##     between, first, last
```

Lo primero que voy a hacer es importar todos los datasets:

```
data.games <- read.csv("../../data/games.csv")
data.champs <- read.csv("../../data/champs.csv")
```

Hemos importado varios CSV que harán las tablas de la base de datos.

Importamos los json:

```
lista.championInfo <- fromJSON(file = "../../data/champion_info.json")
lista.championInfo2 <- fromJSON(file="../../data/champion_info_2.json")
lista.summonerSpell <-
fromJSON(file="../../data/summoner_spell_info.json")
```

Tamaño de mis datasets...

```
print( paste0("El tamaño de la tabla de games es de: "))

## [1] "El tamaño de la tabla de games es de: "

object_size(data.games)

## 13 MB
```

Esto me devuelve las filas que tengan NA:

```
data.games[!complete.cases(data.games),]
```

```
##  [1] gameId             creationTime       gameDuration
##  [4] seasonId           winner             firstBlood
##  [7] firstTower         firstInhibitor     firstBaron
## [10] firstDragon        firstRiftHerald    t1_champ1id
## [13] t1_champ1_sum1     t1_champ1_sum2     t1_champ2id
## [16] t1_champ2_sum1     t1_champ2_sum2     t1_champ3id
## [19] t1_champ3_sum1     t1_champ3_sum2     t1_champ4id
## [22] t1_champ4_sum1     t1_champ4_sum2     t1_champ5id
## [25] t1_champ5_sum1     t1_champ5_sum2     t1_towerKills
## [28] t1_inhibitorKills  t1_baronKills      t1_dragonKills
## [31] t1_riftHeraldKills t1_ban1            t1_ban2
## [34] t1_ban3            t1_ban4            t1_ban5
## [37] t2_champ1id        t2_champ1_sum1     t2_champ1_sum2
## [40] t2_champ2id        t2_champ2_sum1     t2_champ2_sum2
## [43] t2_champ3id        t2_champ3_sum1     t2_champ3_sum2
## [46] t2_champ4id        t2_champ4_sum1     t2_champ4_sum2
## [49] t2_champ5id        t2_champ5_sum1     t2_champ5_sum2
## [52] t2_towerKills      t2_inhibitorKills  t2_baronKills
## [55] t2_dragonKills     t2_riftHeraldKills t2_ban1
## [58] t2_ban2            t2_ban3            t2_ban4
## [61] t2_ban5
## <0 rows> (or 0-length row.names)
```

Como podemos ver, no tenemos filas con NA.

Como voy a ir haciendo "pequeños proyectos" para ir sacando conocimiento por ahora no voy a fusionar ninguna tabla de primeras porque no se lo que voy a necesitar. Según se vayan planteando los interrogantes iré jugando con las tablas para conseguir los objetivos

Análisis Exploratorio

Empezamos por el análisis exploratorio de los datos. Para ello, vamos intentar ver conclusiones sobre los mismos:

```
print("Resumen de data.games")
```

```
## [1] "Resumen de data.games"
```

```
summary(data.games) # Las únicas columnas interesantes son la 5 y la 6
```

```
##      gameId           creationTime        gameDuration     seasonId
##  Min.   :3.215e+09   Min.   :1.497e+12   Min.   : 190   Min.   :9
##  1st Qu.:3.292e+09   1st Qu.:1.502e+12   1st Qu.:1531   1st Qu.:9
##  Median :3.320e+09   Median :1.504e+12   Median :1833   Median :9
##  Mean   :3.306e+09   Mean   :1.503e+12   Mean   :1832   Mean   :9
```

```
##  3rd Qu.:3.327e+09   3rd Qu.:1.504e+12   3rd Qu.:2148   3rd Qu.:9
##  Max.   :3.332e+09   Max.   :1.505e+12   Max.   :4728   Max.   :9
##      winner        firstBlood      firstTower    firstInhibitor
##  Min.   :1.000   Min.   :0.000   Min.   :0.000   Min.   :0.000
##  1st Qu.:1.000   1st Qu.:1.000   1st Qu.:1.000   1st Qu.:1.000
##  Median :1.000   Median :1.000   Median :1.000   Median :1.000
##  Mean   :1.494   Mean   :1.471   Mean   :1.451   Mean   :1.308
##  3rd Qu.:2.000   3rd Qu.:2.000   3rd Qu.:2.000   3rd Qu.:2.000
##  Max.   :2.000   Max.   :2.000   Max.   :2.000   Max.   :2.000
##    firstBaron      firstDragon    firstRiftHerald   t1_champ1id
##  Min.   :0.0000   Min.   :0.000   Min.   :0.0000   Min.   :  1.0
##  1st Qu.:0.0000   1st Qu.:1.000   1st Qu.:0.0000   1st Qu.: 35.0
##  Median :1.0000   Median :1.000   Median :0.0000   Median : 79.0
##  Mean   :0.9265   Mean   :1.443   Mean   :0.7317   Mean   :114.3
##  3rd Qu.:2.0000   3rd Qu.:2.000   3rd Qu.:1.0000   3rd Qu.:136.0
##  Max.   :2.0000   Max.   :2.000   Max.   :2.0000   Max.   :516.0
##  t1_champ1_sum1   t1_champ1_sum2    t1_champ2id    t1_champ2_sum1
##  Min.   : 1.000   Min.   : 1.000   Min.   :  1.0   Min.   : 1.000
##  1st Qu.: 4.000   1st Qu.: 4.000   1st Qu.: 35.0   1st Qu.: 4.000
##  Median : 4.000   Median : 4.000   Median : 79.0   Median : 4.000
##  Mean   : 6.602   Mean   : 7.334   Mean   :118.1   Mean   : 6.548
##  3rd Qu.:11.000   3rd Qu.:11.000   3rd Qu.:141.0   3rd Qu.:11.000
##  Max.   :21.000   Max.   :21.000   Max.   :516.0   Max.   :21.000
##  t1_champ2_sum2    t1_champ3id    t1_champ3_sum1   t1_champ3_sum2
##  Min.   : 1.000   Min.   :  1.0   Min.   : 1.000   Min.   : 1.000
##  1st Qu.: 4.000   1st Qu.: 35.0   1st Qu.: 4.000   1st Qu.: 4.000
##  Median : 4.000   Median : 78.0   Median : 4.000   Median : 4.000
##  Mean   : 7.198   Mean   :116.9   Mean   : 6.542   Mean   : 7.201
##  3rd Qu.:11.000   3rd Qu.:141.0   3rd Qu.:11.000   3rd Qu.:11.000
##  Max.   :21.000   Max.   :516.0   Max.   :21.000   Max.   :21.000
##   t1_champ4id    t1_champ4_sum1   t1_champ4_sum2    t1_champ5id
##  Min.   :  1.0   Min.   : 1.000   Min.   : 1.000   Min.   :  1.0
##  1st Qu.: 36.0   1st Qu.: 4.000   1st Qu.: 4.000   1st Qu.: 35.0
##  Median : 79.0   Median : 4.000   Median : 4.000   Median : 78.0
##  Mean   :117.7   Mean   : 6.531   Mean   : 7.221   Mean   :114.6
##  3rd Qu.:141.0   3rd Qu.:11.000   3rd Qu.:11.000   3rd Qu.:136.0
##  Max.   :516.0   Max.   :21.000   Max.   :21.000   Max.   :516.0
##  t1_champ5_sum1   t1_champ5_sum2   t1_towerKills    t1_inhibitorKills
##  Min.   : 1.000   Min.   : 1.000   Min.   : 0.000   Min.   : 0.000
##  1st Qu.: 4.000   1st Qu.: 4.000   1st Qu.: 2.000   1st Qu.: 0.000
##  Median : 4.000   Median : 4.000   Median : 6.000   Median : 1.000
##  Mean   : 6.622   Mean   : 7.261   Mean   : 5.699   Mean   : 1.018
##  3rd Qu.:11.000   3rd Qu.:11.000   3rd Qu.: 9.000   3rd Qu.: 2.000
##  Max.   :21.000   Max.   :21.000   Max.   :11.000   Max.   :10.000
##  t1_baronKills    t1_dragonKills  t1_riftHeraldKills    t1_ban1
##  Min.   :0.0000   Min.   :0.000   Min.   :0.0000     Min.   : -1.0
##  1st Qu.:0.0000   1st Qu.:0.000   1st Qu.:0.0000     1st Qu.: 38.0
##  Median :0.0000   Median :1.000   Median :0.0000     Median : 90.0
##  Mean   :0.3723   Mean   :1.387   Mean   :0.2515     Mean   :108.3
##  3rd Qu.:1.0000   3rd Qu.:2.000   3rd Qu.:1.0000     3rd Qu.:141.0
```

```
##  Max.   :5.0000   Max.   :6.000   Max.   :1.0000     Max.   :516.0
##     t1_ban2         t1_ban3         t1_ban4         t1_ban5
##  Min.   : -1.0   Min.   : -1.0   Min.   : -1.0   Min.   : -1
##  1st Qu.: 38.0   1st Qu.: 37.0   1st Qu.: 38.0   1st Qu.: 38
##  Median : 90.0   Median : 90.0   Median : 89.0   Median : 90
##  Mean   :108.8   Mean   :108.2   Mean   :107.6   Mean   :109
##  3rd Qu.:141.0   3rd Qu.:141.0   3rd Qu.:141.0   3rd Qu.:141
##  Max.   :516.0   Max.   :516.0   Max.   :516.0   Max.   :516
##   t2_champ1id    t2_champ1_sum1   t2_champ1_sum2    t2_champ2id
##  Min.   :  1.0   Min.   : 1.000   Min.   : 1.000   Min.   :  1.0
##  1st Qu.: 35.0   1st Qu.: 4.000   1st Qu.: 4.000   1st Qu.: 35.0
##  Median : 78.0   Median : 4.000   Median : 4.000   Median : 79.0
##  Mean   :115.9   Mean   : 6.595   Mean   : 7.305   Mean   :117.6
##  3rd Qu.:141.0   3rd Qu.:11.000   3rd Qu.:11.000   3rd Qu.:141.0
##  Max.   :516.0   Max.   :21.000   Max.   :21.000   Max.   :516.0
##  t2_champ2_sum1   t2_champ2_sum2    t2_champ3id    t2_champ3_sum1
##  Min.   : 1.000   Min.   : 1.000   Min.   :  1.0   Min.   : 1.000
##  1st Qu.: 4.000   1st Qu.: 4.000   1st Qu.: 36.0   1st Qu.: 4.000
##  Median : 4.000   Median : 4.000   Median : 79.0   Median : 4.000
##  Mean   : 6.547   Mean   : 7.231   Mean   :117.5   Mean   : 6.522
##  3rd Qu.:11.000   3rd Qu.:11.000   3rd Qu.:141.0   3rd Qu.:11.000
##  Max.   :21.000   Max.   :21.000   Max.   :516.0   Max.   :21.000
##  t2_champ3_sum2    t2_champ4id    t2_champ4_sum1   t2_champ4_sum2
##  Min.   : 1.000   Min.   :  1.0   Min.   : 1.000   Min.   : 1.000
##  1st Qu.: 4.000   1st Qu.: 35.0   1st Qu.: 4.000   1st Qu.: 4.000
##  Median : 4.000   Median : 79.0   Median : 4.000   Median : 4.000
##  Mean   : 7.227   Mean   :118.2   Mean   : 6.535   Mean   : 7.201
##  3rd Qu.:11.000   3rd Qu.:141.0   3rd Qu.:11.000   3rd Qu.:11.000
##  Max.   :21.000   Max.   :516.0   Max.   :21.000   Max.   :21.000
##   t2_champ5id    t2_champ5_sum1   t2_champ5_sum2  t2_towerKills
##  Min.   :  1.0   Min.   : 1.000   Min.   : 1.00   Min.   : 0.000
##  1st Qu.: 35.0   1st Qu.: 4.000   1st Qu.: 4.00   1st Qu.: 2.000
##  Median : 78.0   Median : 4.000   Median : 4.00   Median : 6.000
##  Mean   :115.9   Mean   : 6.613   Mean   : 7.25   Mean   : 5.549
##  3rd Qu.:141.0   3rd Qu.:11.000   3rd Qu.:11.00   3rd Qu.: 9.000
##  Max.   :516.0   Max.   :21.000   Max.   :21.00   Max.   :11.000
##  t2_inhibitorKills t2_baronKills    t2_dragonKills  t2_riftHeraldKills
##  Min.   : 0.0000   Min.   :0.0000   Min.   :0.000   Min.   :0.0000
##  1st Qu.: 0.0000   1st Qu.:0.0000   1st Qu.:0.000   1st Qu.:0.0000
##  Median : 0.0000   Median :0.0000   Median :1.000   Median :0.0000
##  Mean   : 0.9851   Mean   :0.4145   Mean   :1.404   Mean   :0.2401
##  3rd Qu.: 2.0000   3rd Qu.:1.0000   3rd Qu.:2.000   3rd Qu.:0.0000
##  Max.   :10.0000   Max.   :4.0000   Max.   :6.000   Max.   :1.0000
##     t2_ban1         t2_ban2         t2_ban3         t2_ban4
##  Min.   : -1.0   Min.   : -1.0   Min.   : -1.0   Min.   : -1.0
##  1st Qu.: 38.0   1st Qu.: 37.0   1st Qu.: 38.0   1st Qu.: 38.0
##  Median : 90.0   Median : 90.0   Median : 90.0   Median : 90.0
##  Mean   :108.2   Mean   :107.9   Mean   :108.7   Mean   :108.6
##  3rd Qu.:141.0   3rd Qu.:141.0   3rd Qu.:141.0   3rd Qu.:141.0
##  Max.   :516.0   Max.   :516.0   Max.   :516.0   Max.   :516.0
```

```
##     t2_ban5
##  Min.   : -1.0
##  1st Qu.: 38.0
##  Median : 90.0
##  Mean   :108.1
##  3rd Qu.:141.0
##  Max.   :516.0
```

Una vez que tenemos los estadísticos básicos principales, vamos a limpiar algunos datasets de variables que no necesitamos para poder hacer análisis de variables con su correlación y similares...

```
# Ahora voy a hacer una tabla de games especial solo con las variables de las que calcularemos las correlaciones
# Game ID es una variable que no necesito para nada, por lo que la voy a eliminar:

data.games.corr <- data.games[, c(-1, -4)]
#head(data.games.corr)
data.games.corr <- data.games.corr[, -10:-24]
#head(data.games.corr)
data.games.corr <- data.games.corr[, -15:-34]
#head(data.games.corr)
data.games.corr <- data.games.corr[, -20:-24]
```

Correlation Plots

Lo primero que voy a hacer son los correlation plot de cada una de las tablas. Vamos a ver qué relaciones tenemos entre los datos, para poder ver si podemos ir sacando algunas conclusiones...

```
res.games <- cor(data.games.corr, method = "spearman")
options(width = 100)
res.games.round <- round(res.games, 2)
```

El primer gráfico que muestro es entre la duración de las partidas y la temporada en la que se está jugando:

```
corrplot(res.games.round, method="circle", type = "upper")
```

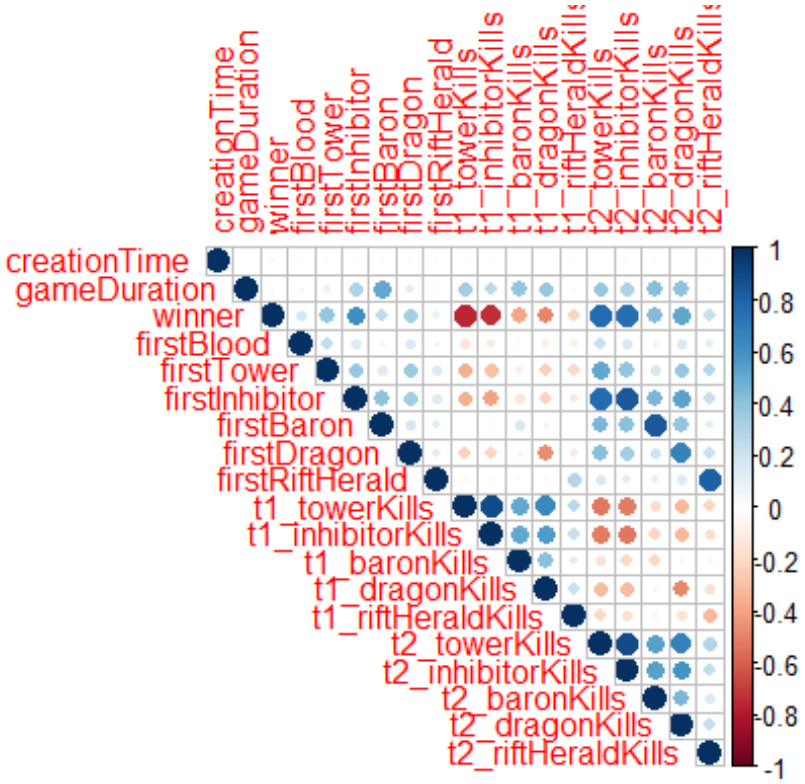

Exportamos el corrplot a PDF para tenerlo vectorial y poderlo ver mejor...

```
pdf("../imagenes/corrplot.pdf")
corrplot(res.games.round, method="circle", type = "upper")
dev.off
```

```
## function (which = dev.cur())
## {
##     if (which == 1)
##         stop("cannot shut down device 1 (the null device)")
##     .External(C_devoff, as.integer(which))
##     dev.cur()
## }
## <bytecode: 0x00000000134d26f0>
## <environment: namespace:grDevices>
```

Podemos apreciar las siguientes correlaciones sobre destruir torres:

- Destruir más torres tiene una relación directa con destruir inhibidores
- Destruir más torres tiene una cierta relación directa con matar dragones
- Destruir más torres tiene una cierta relación inversa con que el equipo contrario destruya tus torres
- Destruir más torres tiene uan cierta relación con que el equipo contrario mate menos dragones

Respecto a ganar, obtenemos las siguientes correlaciones:

- Muchas veces, quien destruye el primer inhibidor es el equipo que acaba ganando la partida
- Un aumento en que el equipo 1 destruya más torres tiene que ver con que tengan más posibilidades de victoria. Esto se da con una relación inversa, ya que la victoria del equipo 1 se marca con un 1, la del 2 con un dos, y el aumento de towerkills de t1 implica una bajada en win (1 en vez de dos)
- Lo mismi pasa con la cantidad de inhibidores destruidos, donde es también una relación muy fuerte la que hay.
- Con el equipo 2 pasa lo mismo, lo que pasa es que, por lo explicado anteriormente, en este caso se muestra como relación direta, y de este modo podemos ver las mismas correlaciones de una parte que de otra.

Respecto a dragones, podemos ver:

- Es más importante para el equipo 2 hacerse el primer dragón de cara a hacerse más que el que el equipo 1 haga el mismo.

Finalmente, respecto a el momento de la creación de la partida, podemos observar:

- No tiene ninguna relación el paso del tiempo cno el aumento o disminución de ninguna de las variables.

PCA

Vamos a hacer ahora un análisis de las componentes principales: Para los cálculos, uso la matriz con el centrado y escalado ya hechos

```
resultado.pca <- PCA(data.games.corr, graph = FALSE)

#Con la siguiente línea podemos ver que podemos hacer con esto calculado
print(resultado.pca)
```

```
## **Results for the Principal Component Analysis (PCA)**
## The analysis was performed on 51490 individuals, described by 19
variables
## *The results are available in the following objects:
##
##    name               description
## 1  "$eig"             "eigenvalues"
## 2  "$var"             "results for the variables"
## 3  "$var$coord"       "coord. for the variables"
## 4  "$var$cor"         "correlations variables - dimensions"
## 5  "$var$cos2"        "cos2 for the variables"
## 6  "$var$contrib"     "contributions of the variables"
## 7  "$ind"             "results for the individuals"
## 8  "$ind$coord"       "coord. for the individuals"
## 9  "$ind$cos2"        "cos2 for the individuals"
## 10 "$ind$contrib"     "contributions of the individuals"
## 11 "$call"            "summary statistics"
```

```
## 12 "$call$centre"     "mean of the variables"
## 13 "$call$ecart.type" "standard error of the variables"
## 14 "$call$row.w"      "weights for the individuals"
## 15 "$call$col.w"      "weights for the variables"
```

Nos interesa ver los eigenvalues, que son los que presentarán la cantidad de varianza que aportan las variables:

```
eigenvalues.PCA <- resultado.pca$eig
eigenvalues.PCA
```

```
##           eigenvalue percentage of variance cumulative percentage of
variance
## comp 1  6.064459e+00           3.191820e+01
31.91820
## comp 2  3.000738e+00           1.579336e+01
47.71156
## comp 3  1.771844e+00           9.325495e+00
57.03706
## comp 4  1.316075e+00           6.926710e+00
63.96377
## comp 5  1.066890e+00           5.615210e+00
69.57898
## comp 6  9.958756e-01           5.241450e+00
74.82043
## comp 7  9.704525e-01           5.107645e+00
79.92807
## comp 8  8.740157e-01           4.600083e+00
84.52816
## comp 9  6.403057e-01           3.370030e+00
87.89819
## comp 10 5.797901e-01           3.051527e+00
90.94971
## comp 11 4.053622e-01           2.133485e+00
93.08320
## comp 12 3.670873e-01           1.932039e+00
95.01524
## comp 13 2.816983e-01           1.482623e+00
96.49786
## comp 14 2.465127e-01           1.297435e+00
97.79529
## comp 15 1.253587e-01           6.597825e-01
98.45508
## comp 16 1.175431e-01           6.186477e-01
99.07372
## comp 17 1.007805e-01           5.304239e-01
99.60415
## comp 18 7.521185e-02           3.958518e-01
100.00000
## comp 19 7.248996e-26           3.815261e-25
100.00000
```

Como podemos ver, tenemos 19 componentes principales (una por cada dimensión), y vemos que solo con 10 variables ya tenemos un 90% de explicación. Además, de cara a la representación en dos dimensiones, podemos ver que con solo las dos variables con más varianza tenemos una explicación del 47,7%.

Ahora, para completar este apartado de PCA, lo que voy a hacer es sacar la gráfica de la varianza acumulada con los valores anteriores:

```
plotPCA <- fviz_screeplot(resultado.pca, ncp=19, main="Barplot de
explicación de varianza", ylab="Porcentaje de explicación",
xlab="Dimensión")
plot(plotPCA)
```

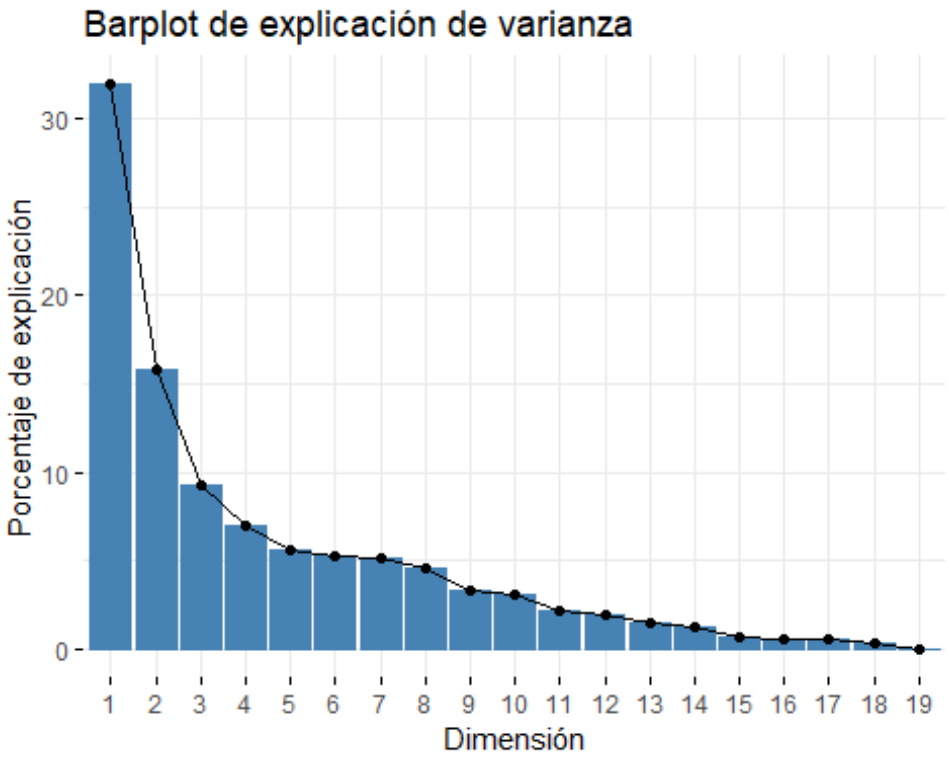

Ahora voy a sacar un "Factor Map" de las variables. Esto lo puedo hacer gracias a las coordenadas que me da una de las variables tras hacer el PCA. Así, voy primero a ver la tabla y luego voy a sacar el mapa:

```
head(resultado.pca$var$coord)

##                     Dim.1       Dim.2       Dim.3       Dim.4
Dim.5
## creationTime   0.01723817 -0.01149443 -0.06290260  0.04393011 -
0.25111184
## gameDuration   0.24050089  0.86002372 -0.09989262  0.13764973 -
0.07795331
## winner         0.84048823 -0.23457181 -0.14685233 -0.11282396 -
0.04006251
```

```
## firstBlood     0.26968344  0.05182651  0.13357189  0.34780625 -
0.23151329
## firstTower     0.55683600  0.07472362  0.19566560  0.37066228 -
0.14932506
## firstInhibitor 0.72099264  0.28414084 -0.07367165 -0.02461892 -
0.03806185
```

Como se puede ver, me está poniendo mis 24 variables en 5 dimensiones, con unas coordenadas concretas. Ahora, lo que voy a hacer, es representarlo. Con esta representación podré sacar algunas conclusiones:

```
fviz_pca_var(resultado.pca)
```

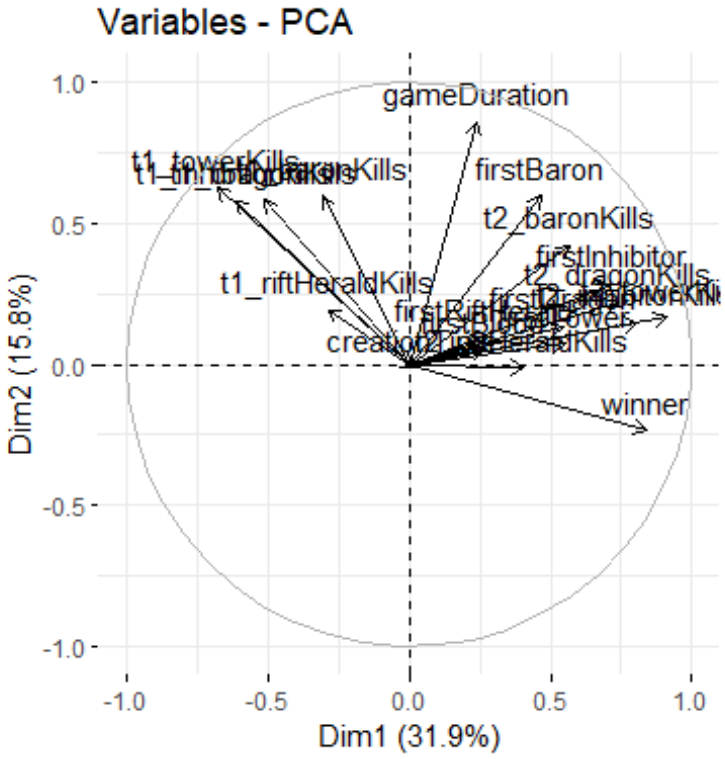

Es interesante ver como no hay nada que vaya en la misma dirección que la victoria. T1 tiene que ser interpretado de una manera en espejo respecto al eje de las Y, y vemos como muchísimas variables como el heraldo, first blood, número de dragones… todas tienen más o menos la misma importancia de cara a conseguir la victoria.

Vemos como la duración del juego forma un ángulo de 90 grados con la victoria, lo cual significa que no tiene nada que ver.

Ahora vamos a ver en un mapa, sobre las dos componentes principales, todas las partidas:

```
fviz_pca_ind(resultado.pca)
```

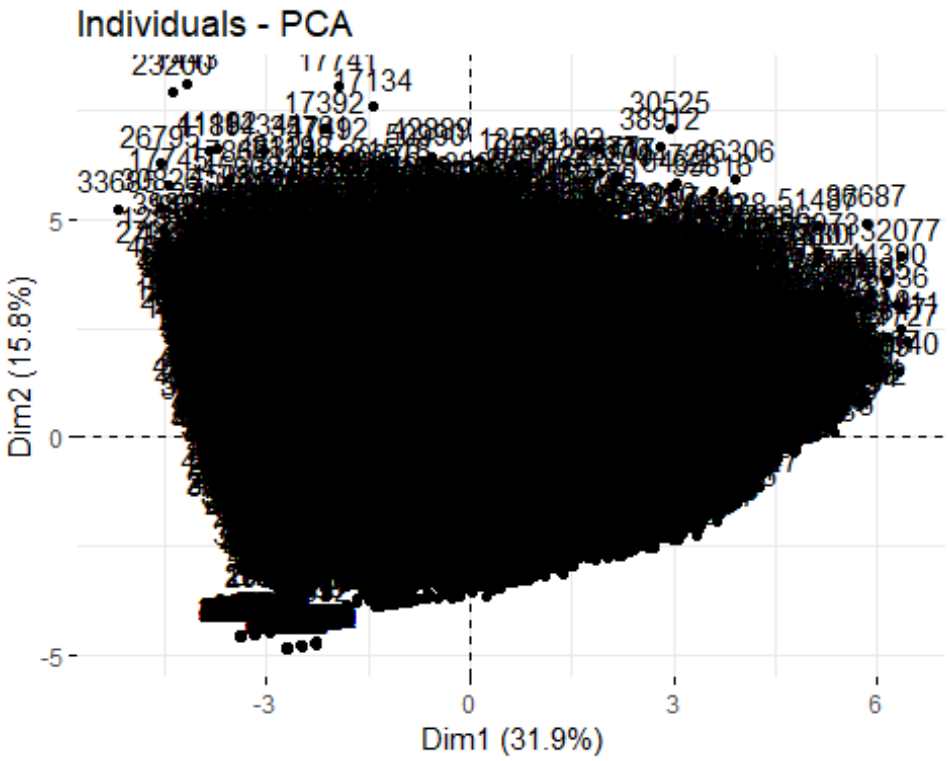

Exportamos estos gráficos del PCA de los individuos...

```
pdf("../imagenes/PCAIndividuos.pdf")

plot(plotPCA)
fviz_pca_var(resultado.pca)
fviz_pca_ind(resultado.pca)

dev.off

## function (which = dev.cur())
## {
##     if (which == 1)
##         stop("cannot shut down device 1 (the null device)")
##     .External(C_devoff, as.integer(which))
##     dev.cur()
## }
## <bytecode: 0x00000000134d26f0>
## <environment: namespace:grDevices>
```

Como se puede apreciar en este gráfico también, prácticamente todas las partidas forman un gran cluster (representado sobre las dos componentes con más variabilidad), y esto nos demuestra que no hay demasiada varianza entre unas partidas y otras. En otras palabras, no podemos distinguir fácilmente varios tipos de partidas, todas son parecidas y no hay diferencias suficientes para clasificar en grupos, más que en uno grande.

Para analizar la variabilidad de algunas partidas, vamos a verlo mediante el método de las caras de Chernoff:

```
muestra_partidas <- data.games[1:16, 27:31]
muestra_partidas <- cbind(muestra_partidas, data.games[1:16, 52:56])
faces(muestra_partidas[1:10], face.type=1,labels=data.games[1:16, 5],
main = "Diferencias entre partidas", scale = TRUE, cex = 1.5)
```

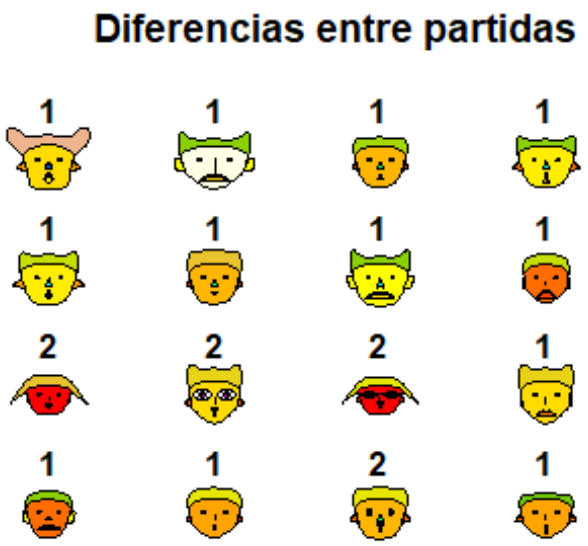


```
## effect of variables:
##  modified item       Var
##  "height of face   " "t1_towerKills"
##  "width of face    " "t1_inhibitorKills"
##  "structure of face" "t1_baronKills"
##  "height of mouth  " "t1_dragonKills"
##  "width of mouth   " "t1_riftHeraldKills"
##  "smiling          " "t2_towerKills"
##  "height of eyes   " "t2_inhibitorKills"
##  "width of eyes    " "t2_baronKills"
##  "height of hair   " "t2_dragonKills"
##  "width of hair    "  "t2_riftHeraldKills"
##  "style of hair    "  "t1_towerKills"
##  "height of nose   "  "t1_inhibitorKills"
##  "width of nose    "  "t1_baronKills"
##  "width of ear     "  "t1_dragonKills"
##  "height of ear    "  "t1_riftHeraldKills"
```

Lo exportamos a PDF para tener más calidad al pasarlo a vectorial…

```
pdf("../imagenes/chernoff partidas.pdf")
faces(muestra_partidas[1:10], face.type=1,labels=data.games[1:16, 5],
main = "Diferencias entre partidas", scale = TRUE, cex = 1.5)
```

```
## effect of variables:
##  modified item       Var
##  "height of face   " "t1_towerKills"
##  "width of face    " "t1_inhibitorKills"
##  "structure of face" "t1_baronKills"
##  "height of mouth  " "t1_dragonKills"
##  "width of mouth   " "t1_riftHeraldKills"
##  "smiling          " "t2_towerKills"
##  "height of eyes   " "t2_inhibitorKills"
##  "width of eyes    " "t2_baronKills"
##  "height of hair   " "t2_dragonKills"
##  "width of hair    "  "t2_riftHeraldKills"
##  "style of hair    "  "t1_towerKills"
##  "height of nose   "  "t1_inhibitorKills"
##  "width of nose    "  "t1_baronKills"
##  "width of ear     "  "t1_dragonKills"
##  "height of ear    "  "t1_riftHeraldKills"
```

```
dev.off
```

```
## function (which = dev.cur())
## {
##     if (which == 1)
##         stop("cannot shut down device 1 (the null device)")
##     .External(C_devoff, as.integer(which))
##     dev.cur()
## }
## <bytecode: 0x00000000134d26f0>
## <environment: namespace:grDevices>
```

Como podemos ver, hay diferencias entre las partidas ganadas por el equipo 1 (caras en general más grandes y geométricas, pelo hacia arriba) y las del equipo 2 (pelo hacia abajo y amarillo, cara roja en la mitad, cara redondeada...)

Preguntas

Ahora que tenemos las correlaciones vistas, podemos pasar a hacernos preguntas.

¿Campeón más baneado por temporada?

Uno de los elementos que más se tienen en cuenta a la hora de analizar el League of Legends en los e-sports es el campeón más baneado por temporada o campeonato. Esto es porque desde Riot Games hacen cambios a las habilidades y fuerza de los personajes, de tal manera que algunas veces algunos campeones son demasiado fuertes y se pueden bloquear al inicio de la partida. Vamos a ver cuáles han sido:

Para analizar esto, contaré la cantidad de ocurrencias y veré, en estas más de 50.000 partidas, cual es el campeón más temido entre los jugadores, tras sustiruir por los nombres.

```
# Lo que voy a hacer es contar por columnas, y luego sumo todas las
columnas que he contado. Así obtengo el recuento final

# TEAM 1

cont.bans.t1.1 <- ddply(data.games,.(t1_ban1),nrow)
cont.bans.t1.1 <- cont.bans.t1.1[order(cont.bans.t1.1$V1, decreasing =
TRUE), ]
cont.bans.t1.2 <- ddply(data.games,.(t1_ban2),nrow)
cont.bans.t1.2 <- cont.bans.t1.2[order(cont.bans.t1.2$V1, decreasing =
TRUE), ]
cont.bans.t1.3 <- ddply(data.games,.(t1_ban3),nrow)
cont.bans.t1.3 <- cont.bans.t1.3[order(cont.bans.t1.3$V1, decreasing =
TRUE), ]
cont.bans.t1.4 <- ddply(data.games,.(t1_ban4),nrow)
cont.bans.t1.4 <- cont.bans.t1.4[order(cont.bans.t1.4$V1, decreasing =
TRUE), ]
cont.bans.t1.5 <- ddply(data.games,.(t1_ban5),nrow)
cont.bans.t1.5 <- cont.bans.t1.5[order(cont.bans.t1.5$V1, decreasing =
TRUE), ]

# TEAM 2

cont.bans.t2.1 <- ddply(data.games,.(t2_ban1),nrow)
cont.bans.t2.1 <- cont.bans.t2.1[order(cont.bans.t2.1$V1, decreasing =
TRUE), ]
cont.bans.t2.2 <- ddply(data.games,.(t2_ban2),nrow)
cont.bans.t2.2 <- cont.bans.t2.2[order(cont.bans.t2.2$V1, decreasing =
TRUE), ]
cont.bans.t2.3 <- ddply(data.games,.(t2_ban3),nrow)
cont.bans.t2.3 <- cont.bans.t2.3[order(cont.bans.t2.3$V1, decreasing =
TRUE), ]
cont.bans.t2.4 <- ddply(data.games,.(t2_ban4),nrow)
cont.bans.t2.4 <- cont.bans.t2.4[order(cont.bans.t2.4$V1, decreasing =
TRUE), ]
cont.bans.t2.5 <- ddply(data.games,.(t2_ban5),nrow)
cont.bans.t2.5 <- cont.bans.t2.5[order(cont.bans.t2.5$V1, decreasing =
TRUE), ]

# Ahora lo que tengo que hacer es sumar todas estas columnas de V1 según
el valor de name...

df.bans <- left_join(cont.bans.t1.1, cont.bans.t1.2, by =c("t1_ban1" =
"t1_ban2"))
df.bans <- left_join(df.bans, cont.bans.t1.3, by =c("t1_ban1" =
```

```
"t1_ban3"))
df.bans <- left_join(df.bans, cont.bans.t1.4, by =c("t1_ban1" =
"t1_ban4"))
df.bans <- left_join(df.bans, cont.bans.t1.5, by =c("t1_ban1" =
"t1_ban5"))

df.bans <- left_join(df.bans, cont.bans.t2.1, by =c("t1_ban1" =
"t2_ban1"))
df.bans <- left_join(df.bans, cont.bans.t2.2, by =c("t1_ban1" =
"t2_ban2"))
df.bans <- left_join(df.bans, cont.bans.t2.3, by =c("t1_ban1" =
"t2_ban3"))
df.bans <- left_join(df.bans, cont.bans.t2.4, by =c("t1_ban1" =
"t2_ban4"))
df.bans <- left_join(df.bans, cont.bans.t2.5, by =c("t1_ban1" =
"t2_ban5"))

df.bans$total <- rowSums( df.bans[,2:11] )

remove(cont.bans.t1.1)
remove(cont.bans.t1.2)
remove(cont.bans.t1.3)
remove(cont.bans.t1.4)
remove(cont.bans.t1.5)
remove(cont.bans.t2.1)
remove(cont.bans.t2.2)
remove(cont.bans.t2.3)
remove(cont.bans.t2.4)
remove(cont.bans.t2.5)

df.bans <- df.bans[order(df.bans$total, decreasing = TRUE), ]
df.bans <- df.bans[, -2:-11]
head(df.bans)

##   t1_ban1 total
## 1     157 33015
## 2     238 25393
## 3      31 25175
## 4     122 22870
## 5      40 21390
## 6     119 20262

# Finalmente, junto con la tabla de data.champs para ponerles nombre...

df.bans <- left_join(df.bans, data.champs, by=c("t1_ban1" = "id"))
df.bans <- df.bans[, -1]
head(df.bans)

##   total    name
## 1 33015   Yasuo
```

```
## 2 25393     Zed
## 3 25175 ChoGath
## 4 22870  Darius
## 5 21390   Janna
## 6 20262  Draven
```

Ahora que tenemos todos los bans contados, es hora de hacer un wordcloud para poder verlo visualmente:

```
set.seed(9999) # Para el mantenimiento del mismo patrón

wordcloud(words = df.bans$name, freq = df.bans$total, min.freq = 1,
random.order=FALSE,
          rot.per=0.5, colors=c("Orange","Purple","Pink", "Red",
"Yellow", "Green", "Blue", "Black"))
```

```
## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Fiddlesticks could
## not be fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Nidalee could not
## be fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Mordekaiser could
## not be fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Taric could not be
## fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Lissandra could not
## be fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Volibear could not
## be fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Poppy could not be
## fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Karthus could not
## be fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Udyr could not be
## fit on page. It will not be plotted.
```

```
## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Skarner could not
## be fit on page. It will not be plotted.
```


```
# Ratio del más baneado

print("El porcentaje de baneo a Yasuo es de: ")

## [1] "El porcentaje de baneo a Yasuo es de: "

ratio.ban.yasuo <- df.bans$total[1]/sum(df.bans$total)
print(ratio.ban.yasuo)

## [1] 0.06411925
```

Exportamos el wordcloud a PDF para tenerlo vectorial...

```
set.seed(9999) # Para el mantenimiento del mismo patrón

wordcloud(words = df.bans$name, freq = df.bans$total, min.freq = 1,
random.order=FALSE,
          rot.per=0.5, colors=c("Orange","Purple","Pink", "Red",
"Yellow", "Green", "Blue", "Black"))

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Fiddlesticks could
## not be fit on page. It will not be plotted.
```

```
## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Nidalee could not
## be fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Mordekaiser could
## not be fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Taric could not be
## fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Lissandra could not
## be fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Volibear could not
## be fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Poppy could not be
## fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Karthus could not
## be fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Udyr could not be
## fit on page. It will not be plotted.

## Warning in wordcloud(words = df.bans$name, freq = df.bans$total,
min.freq = 1, : Skarner could not
## be fit on page. It will not be plotted.
```


```
dev.off

## function (which = dev.cur())
## {
##     if (which == 1)
##         stop("cannot shut down device 1 (the null device)")
##     .External(C_devoff, as.integer(which))
##     dev.cur()
## }
## <bytecode: 0x00000000134d26f0>
## <environment: namespace:grDevices>
```

Pregunta respondida.

¿Matar un mayor número de dragones aumenta las posibilidades de victoria?

Esto lo vamos a responder para el equipo 1 y para el equipo 2, de tal manera que podamos ver si tiene más influencia en uno u en otro.

Para esto, necesito la cantidad de dragones matados por el equipo que venció y por el equipo que perdió, y esos datos los tengo en el dataset de data.games.

```
data.dragons.win <- cbind(data.games$t1_dragonKills,
data.games$t2_dragonKills, data.games$winner)
colnames(data.dragons.win) <- c("KillsT1", "KillsT2", "Win")
head(data.dragons.win)
```

```
##      KillsT1 KillsT2 Win
## [1,]       3       1   1
## [2,]       2       0   1
## [3,]       1       1   1
## [4,]       2       0   1
## [5,]       3       1   1
## [6,]       1       3   1
```

Primero vamos a estudiar la correlación. La hemos visto anteriormente, pero vamos a hacerlo ahora en especial de esta tabla para verlo de una manera más grande:

```
res.dragons.win <- cor(data.dragons.win, method = "spearman")
options(width = 100)
res.dragons.win.round <- round(res.dragons.win, 2)

corrplot(res.dragons.win.round, method="square", type = "upper", tl.srt =
0.7)
```

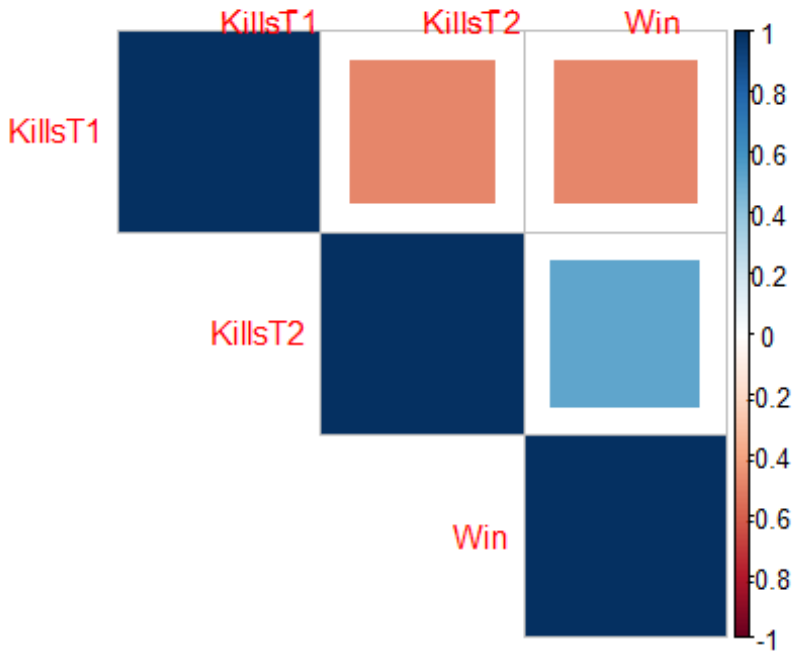

Lo exportamos a PDF para poderlo ver con mayor calidad...

```
pdf("../imagenes/DrakesCorr.pdf")

corrplot(res.dragons.win.round, method="square", type = "upper", tl.srt =
0.7)

dev.off
```

```
## function (which = dev.cur())
## {
##     if (which == 1)
##         stop("cannot shut down device 1 (the null device)")
##     .External(C_devoff, as.integer(which))
##     dev.cur()
## }
## <bytecode: 0x00000000134d26f0>
## <environment: namespace:grDevices>
```

Como podemos ver, tenemos una correlación de aproximadamente el 50% entre el aumento del número de dragones matados y conseguir la victoria.

Equipo 1

Vamos a ver el número de dragones matados por el equipo 1 respecto a la victoria:

```
mosaicplot(table(data.dragons.win[, 1], data.dragons.win[, 3]),
main='Winrate por dragones matados, Equipo 1', shade=TRUE)
```

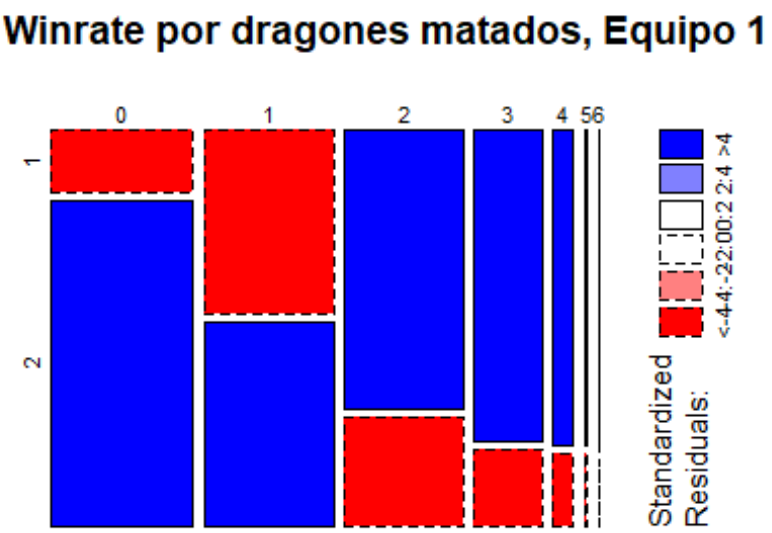

Como podemos ver, el equipo 1, si no mata a ningún dragón, tiene serias posibilidades de no ser el equipo que gane. Conforme va matando dragones, aumenta la posibilidad, especialmente con el paso de 1 a 2 dragones, donde se planta con una mayor parte de las posibilidades.

A partir de los 3 dragones matados, el hecho de matar más no tiene prácticamente influencia en el resultado final.

Equipo 2

Procedemos igual con el equipo 2:

```
mosaicplot(table(data.dragons.win[, 2], data.dragons.win[, 3]),
main='Winrate por dragones matados, Equipo 2', shade=TRUE)
```

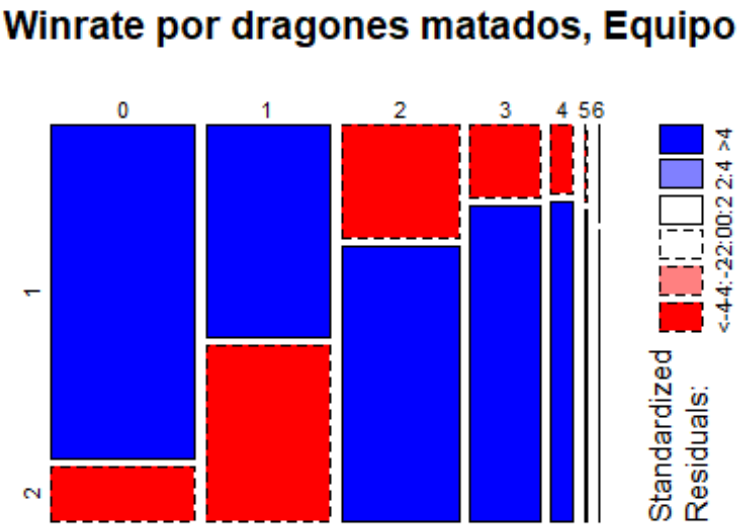

Exportamos los MosaicPlot a PDF para tenerlos vectoriales...

```
pdf("../imagenes/Drakes MosaicPlot.pdf")

mosaicplot(table(data.dragons.win[, 1], data.dragons.win[, 3]),
main='Winrate por dragones matados, Equipo 1', shade=TRUE)
mosaicplot(table(data.dragons.win[, 2], data.dragons.win[, 3]),
main='Winrate por dragones matados, Equipo 2', shade=TRUE)

dev.off
```

```
## function (which = dev.cur())
## {
##     if (which == 1)
##         stop("cannot shut down device 1 (the null device)")
##     .External(C_devoff, as.integer(which))
##     dev.cur()
## }
## <bytecode: 0x00000000134d26f0>
## <environment: namespace:grDevices>
```

Como se puede observar, las distribuciones son prácticamente similares, solo que en espejo como es normal.

¿Cuales son los campeones más escogidos?

Sabemos que Yasuo es el campeón más baneado, con un 6% de banrate. Ahora me pregunto cual es el campeón más escogido para jugar.

Para ello, tenemos que seguir la misma metodología que en la parte de los baneos:

```
# Lo que voy a hacer es contar por columnas, y luego sumo todas las
columnas que he contado. Así obtengo el recuento final

# TEAM 1

cont.picks.t1.1 <- ddply(data.games,.(t1_champ1id),nrow)
cont.picks.t1.1 <- cont.picks.t1.1[order(cont.picks.t1.1$V1, decreasing =
TRUE), ]
cont.picks.t1.2 <- ddply(data.games,.(t1_champ2id),nrow)
cont.picks.t1.2 <- cont.picks.t1.2[order(cont.picks.t1.2$V1, decreasing =
TRUE), ]
cont.picks.t1.3 <- ddply(data.games,.(t1_champ3id),nrow)
cont.picks.t1.3 <- cont.picks.t1.3[order(cont.picks.t1.3$V1, decreasing =
TRUE), ]
cont.picks.t1.4 <- ddply(data.games,.(t1_champ4id),nrow)
cont.picks.t1.4 <- cont.picks.t1.4[order(cont.picks.t1.4$V1, decreasing =
TRUE), ]
cont.picks.t1.5 <- ddply(data.games,.(t1_champ5id),nrow)
cont.picks.t1.5 <- cont.picks.t1.5[order(cont.picks.t1.5$V1, decreasing =
TRUE), ]

# TEAM 2

cont.picks.t2.1 <- ddply(data.games,.(t2_champ1id),nrow)
cont.picks.t2.1 <- cont.picks.t2.1[order(cont.picks.t2.1$V1, decreasing =
TRUE), ]
cont.picks.t2.2 <- ddply(data.games,.(t2_champ2id),nrow)
cont.picks.t2.2 <- cont.picks.t2.2[order(cont.picks.t2.2$V1, decreasing =
TRUE), ]
cont.picks.t2.3 <- ddply(data.games,.(t2_champ3id),nrow)
cont.picks.t2.3 <- cont.picks.t2.3[order(cont.picks.t2.3$V1, decreasing =
TRUE), ]
cont.picks.t2.4 <- ddply(data.games,.(t2_champ4id),nrow)
cont.picks.t2.4 <- cont.picks.t2.4[order(cont.picks.t2.4$V1, decreasing =
TRUE), ]
cont.picks.t2.5 <- ddply(data.games,.(t2_champ5id),nrow)
cont.picks.t2.5 <- cont.picks.t2.5[order(cont.picks.t2.5$V1, decreasing =
TRUE), ]

# Ahora lo que tengo que hacer es sumar todas estas columnas de V1 según
```

```r
el valor de name...

df.picks <- left_join(cont.picks.t1.1, cont.picks.t1.2, by
=c("t1_champ1id" = "t1_champ2id"))
df.picks <- left_join(df.picks, cont.picks.t1.3, by =c("t1_champ1id" =
"t1_champ3id"))
df.picks <- left_join(df.picks, cont.picks.t1.4, by =c("t1_champ1id" =
"t1_champ4id"))
df.picks <- left_join(df.picks, cont.picks.t1.5, by =c("t1_champ1id" =
"t1_champ5id"))

df.picks <- left_join(df.picks, cont.picks.t2.1, by =c("t1_champ1id" =
"t2_champ1id"))
df.picks <- left_join(df.picks, cont.picks.t2.2, by =c("t1_champ1id" =
"t2_champ2id"))
df.picks <- left_join(df.picks, cont.picks.t2.3, by =c("t1_champ1id" =
"t2_champ3id"))
df.picks <- left_join(df.picks, cont.picks.t2.4, by =c("t1_champ1id" =
"t2_champ4id"))
df.picks <- left_join(df.picks, cont.picks.t2.5, by =c("t1_champ1id" =
"t2_champ5id"))

df.picks$total <- rowSums( df.picks[,2:11] )

remove(cont.picks.t1.1)
remove(cont.picks.t1.2)
remove(cont.picks.t1.3)
remove(cont.picks.t1.4)
remove(cont.picks.t1.5)
remove(cont.picks.t2.1)
remove(cont.picks.t2.2)
remove(cont.picks.t2.3)
remove(cont.picks.t2.4)
remove(cont.picks.t2.5)

df.picks <- df.picks[order(df.picks$total, decreasing = TRUE), ]
df.picks <- df.picks[, -2:-11]
head(df.picks)
```

```
##   t1_champ1id total
## 2         412 13002
## 1          18 12983
## 3          67 10658
## 4         141  9853
## 5          64  9188
## 6          29  8838
```

```r
# Finalmente, junto con la tabla de data.champs para ponerles nombre...

df.picks <- left_join(df.picks, data.champs, by=c("t1_champ1id" = "id"))
```

```
df.picks <- df.picks[, -1]
head(df.picks)

##   total     name
## 1 13002   Thresh
## 2 12983 Tristana
## 3 10658    Vayne
## 4  9853     Kayn
## 5  9188  Lee Sin
## 6  8838   Twitch
```

Ahora que tenemos todos los picks contados, es hora de hacer un wordcloud para poder verlo visualmente:

```
set.seed(9998) # Para el mantenimiento del mismo patrón

wordcloud(words = df.picks$name, freq = df.picks$total, min.freq = 3000,
random.order=FALSE,
          rot.per=0.5, colors=c("Orange","Purple","Pink", "Red",
"Yellow", "Green", "Blue", "Black")
         )
```


```
# Ratio del más baneado

print("El porcentaje de pick de Thresh es de: ")

## [1] "El porcentaje de pick de Thresh es de: "
```

```
ratio.pick.thresh <- df.picks$total[1]/sum(df.picks$total)
print(ratio.pick.thresh)
```

```
## [1] 0.02525151
```

Exporto el Wordcloud a PDF para tenerlo vectorial...

```
pdf("../imagenes/wordcloudPicks.pdf")

set.seed(9998) # Para el mantenimiento del mismo patrón

wordcloud(words = df.picks$name, freq = df.picks$total, min.freq = 3000,
random.order=FALSE,
          rot.per=0.5, colors=c("Orange","Purple","Pink", "Red",
"Yellow", "Green", "Blue", "Black")
         )

dev.off
```

```
## function (which = dev.cur())
## {
##     if (which == 1)
##         stop("cannot shut down device 1 (the null device)")
##     .External(C_devoff, as.integer(which))
##     dev.cur()
## }
## <bytecode: 0x00000000134d26f0>
## <environment: namespace:grDevices>
```

Está muy bien que Thresh y Tristana sean los más elegidos, pero... ¿esto es porque conllevan mayor victoria de partidas? Vamos a calcularlo:

¿Qué camepones conllevan un mayor winrate?

Para esto, lo primero que tenemos que hacer es crear un nuevo dataframe con los campeones que han ganado cada partida:

```
dataframe.winners.1 <- filter(data.games, winner == "1")

# En este dataframe, solo me interesan las columnas de los campeones
elegidos por el equipo 1, por lo que solo me quedo con ellas:

dataframe.winners.1 <- dataframe.winners.1[, c(12, 15, 18, 21, 24)]
colnames(dataframe.winners.1) <- c("Pick1", "Pick2", "Pick3", "Pick4",
"Pick5")

# Hacemos lo mismo con los ganadores del equipo 2

dataframe.winners.2 <- filter(data.games, winner == "2")
```

```
# En este dataframe, solo me interesan las columnas de los campeones
elegidos por el equipo 1, por lo que solo me quedo con ellas:

dataframe.winners.2 <- dataframe.winners.2[, c(37, 40, 43, 46, 49)]
colnames(dataframe.winners.2) <- c("Pick1", "Pick2", "Pick3", "Pick4",
"Pick5")

# Ahora los juntamos...

dataframe.winners <- rbind(dataframe.winners.1, dataframe.winners.2)

remove(dataframe.winners.1)
remove(dataframe.winners.2)
```

Ahora ya tenemos preparado el dataframe para poder jugar con él. Procedemos contando el número de ocurrencias que hay de cada campeón, y con esto veremos cual es el campeón que más se repite en este dataframe donde solo están las victorias:

```
# Ahora voy a llevar todas las columnas a una:

dataframe.winners <- data.frame(all = c(dataframe.winners[,"Pick1"],
                                        dataframe.winners[,"Pick2"],
                                        dataframe.winners[,"Pick3"],
                                        dataframe.winners[,"Pick4"],
                                        dataframe.winners[,"Pick5"]))

head(dataframe.winners)

##   all
## 1   8
## 2 119
## 3  18
## 4  57
## 5  19
## 6  40

dataframe.winners <- left_join(dataframe.winners, data.champs, by=c("all"
= "id"))

dataframe.winners <- dataframe.winners[, -1]

head(dataframe.winners)

## [1] Vladimir Draven   Tristana Maokai   Warwick  Janna
## 138 Levels: Aatrox Ahri Akali Alistar Amumu Anivia Annie Ashe Aurelion
Sol Azir Bard ... Zyra

# Ahora tenemos todo el dataframe en una única columna, donde solo nos
queda ordenar y contar el número de ocurrencias:
```

```
dataframe.winners <- dataframe.winners[order(dataframe.winners)]
head(dataframe.winners)
```

```
## [1] Aatrox Aatrox Aatrox Aatrox Aatrox Aatrox
## 138 Levels: Aatrox Ahri Akali Alistar Amumu Anivia Annie Ashe Aurelion
Sol Azir Bard ... Zyra
```

```
# Contamos

cantidad <- as.data.frame(table(dataframe.winners))

cantidad <- cantidad[order(cantidad$Freq, decreasing = TRUE), ]
colnames(cantidad) <- c("name", "freq")
head(cantidad)
```

```
##         name freq
## 112 Tristana 6713
## 111   Thresh 6143
## 120    Vayne 5498
## 42     Janna 4826
## 54      Kayn 4807
## 116   Twitch 4665
```

Como podemos ver, los campeones más elegidos son Tristana y Thresh, que casualmente, como acabamos de probar, son los que tienen más victorias en su haber. También, la tercera con más picks es Vayne, y también es la tercera en cantidad de victorias.

Vamos a calcular el ratio pick-victory:

```
# Para hacer esto, voy a juntar los dos dataframes en uno solo, juntando
por el valor del campeón (nombre), y una vez hecho esto podré restar
entre mismas columnas

# No puedo hacer un join normal porque todos mis elementos de texto son
factors, por eso lo reconvierto

cantidad <- data.frame(cantidad, stringsAsFactors = FALSE)
colnames(cantidad) <- c("name", "freq_win")

df.picks <- data.frame(df.picks, stringsAsFactors = FALSE)
colnames(df.picks) <- c("total_picks", "name")

dataframe.pick.win <- inner_join(cantidad, df.picks, by="name")

# Ahora que tengo los datos a mano, podemos hacer las divisiones:

dataframe.pick.win <- transform(dataframe.pick.win, ratio =
dataframe.pick.win[, 2] / dataframe.pick.win[, 3])
```

```
dataframe.pick.win <- dataframe.pick.win[order(dataframe.pick.win$ratio,
decreasing = TRUE), ]

head(dataframe.pick.win)

##       name freq_win total_picks     ratio
## 4    Janna     4826        8691 0.5552871
## 29    Sona     2942        5429 0.5419046
## 120 Yorick      744        1378 0.5399129
## 66  Rammus     1614        2997 0.5385385
## 87  Anivia     1207        2252 0.5359680
## 118 Singed      762        1425 0.5347368
```

Es interesante ver que, a la vista de estos resultados, la gente banea lo que ve mucho, no lo que de verdad gana partidas. Como podemos observar, Janna, Sona y Yorick son los 3 campeones que más porcentaje de partidas ganan. En cambio, a la hora de escogerlos los vemos en las posiciones 7, 30 y 124. Respecto a bans, si tantas partidas ganan la masa debería de banearlos, pero se encuentran en las posiciones 5, 91 y 96, por lo que la gente no se da cuenta del peligro de estos campeones en las manos adecuadas.

¿El lado rojo (equipo 2) pierde más partidas?

Una de las afirmaciones que corre por la comunidad de League of Legends es la creencia de que el lado rojo, correspondiente con el equipo 2 en nuestro dataset, es el que pierde un mayor número de partidas. Para visualizar esto, lo único que hay que hacer es obtener el winrate del equipo rojo respecto al total de partidas:

```
columna.wins <- data.games$winner
cantidad.wins <- as.data.frame(table(columna.wins))
colnames(cantidad.wins) <- c("winner", "frequency")
head(cantidad.wins)

##   winner frequency
## 1      1     26077
## 2      2     25413

# Si calculamos el ratio...

ratio.red <- cantidad.wins[2, 2] / (cantidad.wins[1, 2] +
cantidad.wins[2, 2])
ratio.red

## [1] 0.4935521

ratio.blue <- cantidad.wins[1, 2] / (cantidad.wins[1, 2] +
cantidad.wins[2, 2])
ratio.blue

## [1] 0.5064479
```

Es decir, el grupo que juega en el lado rojo gana el 49,35% de las partidas, mientras que el que juega en el lado azul gana el 50,64%.

Vamos a verlo en forma de gráfica:

```
ratios_win <- c(ratio.blue, ratio.red)
barplot(ratios_win, main="Victorias por equipo", ylab="Equipo", col =
c("Blue", "Red"))
```


```
pie(table(data.games$winner), main = "Victorias por equipo", col =
c("Blue", "Red"))
```

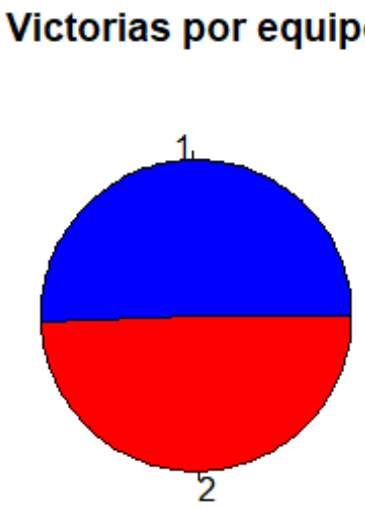

Lo exportamos a PDF...

```
pdf("../imagenes/Winrate Graphs.pdf")
barplot(ratios_win, main="Victorias por equipo", ylab="Equipo", col =
c("Blue", "Red"))
pie(table(data.games$winner), main = "Victorias por equipo", col =
c("Blue", "Red"))
dev.off
```

```
## function (which = dev.cur())
## {
##     if (which == 1)
##         stop("cannot shut down device 1 (the null device)")
##     .External(C_devoff, as.integer(which))
##     dev.cur()
## }
## <bytecode: 0x00000000134d26f0>
## <environment: namespace:grDevices>
```

¿Quién consigue más primeros objetivos?

Los primeros objetivos son cruciales en la partida, ya que algunos dan extra de oro, pero todos empiezan a decantar la partida a tu favor. Debido a ello, el análisis de si existe alguna diferencia entre los equipos a la hora de conseguir los primeros objetivos se plantea crucial.

Para ello, contaré para cada columna de primeros objetivos qué equipo ha conseguido ser el mejor, y por qué porcentaje, y entonces determinaré si hay alguna ventaja en alguno de los objetivos.

```
# Los datos de esto los tenemos en data.games. Para aclarar, vamos a
hacer un dataset específico con los datos de los objetivos...

data.first.objectives <- data.games[, 6:11]

# Es importante remarcar que aquí hay 3 valores: 0 si nadie lo ha
conseguido, 1 si lo ha conseguido el equipo azul y 2 si lo ha conseguido
el equipo rojo.

head(data.first.objectives)

##   firstBlood firstTower firstInhibitor firstBaron firstDragon
firstRiftHerald
## 1          2          1              1          1           1
2
## 2          1          1              1          0           1
1
## 3          2          1              1          1           2
0
## 4          1          1              1          1           1
0
## 5          2          1              1          1           1
0
## 6          2          2              1          1           2
0

# Ahora mi objetivo es contar de cada una de las líneas lo que hay, y de
aquí sacar conclusiones:

firstblood.qty <- as.data.frame(table(data.first.objectives[, 1]))
firsttower.qty <- as.data.frame(table(data.first.objectives[, 2]))
firstinhib.qty <- as.data.frame(table(data.first.objectives[, 3]))
firstbaron.qty <- as.data.frame(table(data.first.objectives[, 4]))
firstdragon.qty <- as.data.frame(table(data.first.objectives[, 5]))
firstherald.qty <- as.data.frame(table(data.first.objectives[, 6]))

# Ahora lo vemos bien en barplots...

array.firstblood <- c(firstblood.qty[1, 2],firstblood.qty[2, 2],
firstblood.qty[3, 2])
barplot(array.firstblood, main="Partidas en las que los equipos hicieron
Primera sangre", xlab="Equipo / Ninguno", ylab = "Número de partidas",
        ylim = c(0,30000), col = c("White", "Blue", "Red"),
legend.text=firstblood.qty$Var1)
```

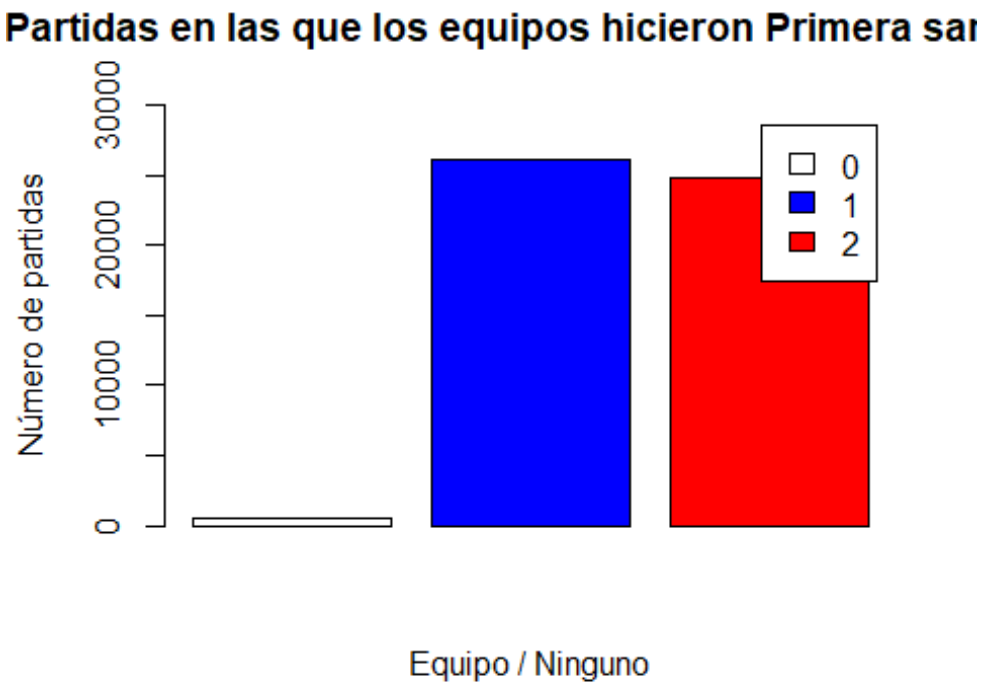


```
array.firsttower <- c(firsttower.qty[1, 2],firsttower.qty[2, 2],
firsttower.qty[3, 2])
barplot(array.firsttower, main="Partidas en las que los equipos hicieron
Primera torre", xlab="Equipo / Ninguno", ylab = "Número de partidas",
        ylim = c(0,30000), col = c("White", "Blue", "Red"),
legend.text=firsttower.qty$Var1)
```

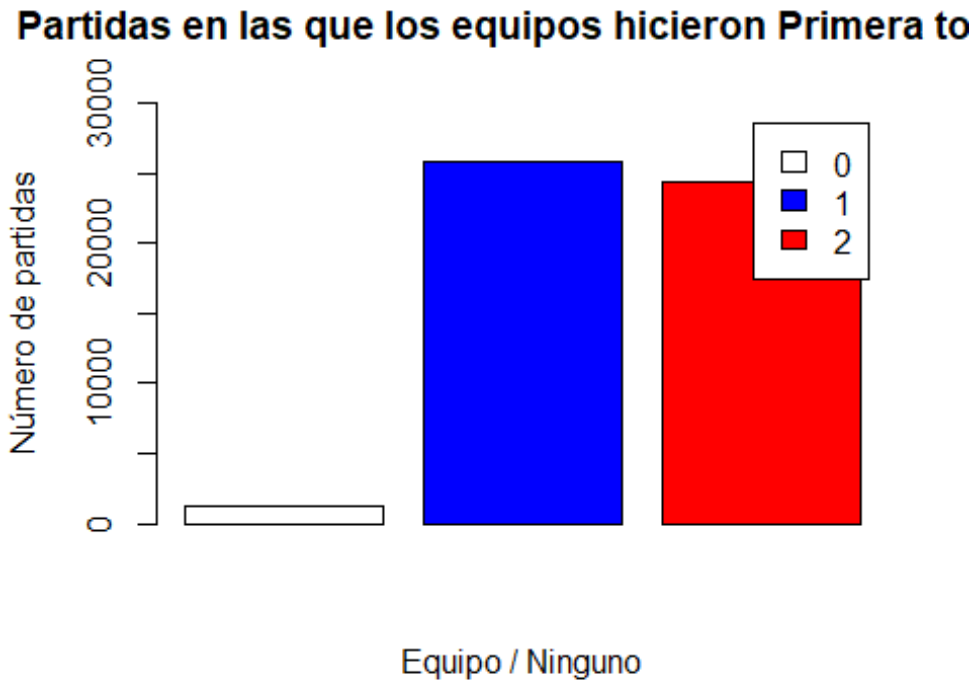


```
array.firstinhib <- c(firstinhib.qty[1, 2],firstinhib.qty[2, 2],
firstinhib.qty[3, 2])
barplot(array.firstinhib, main="Partidas en las que los equipos hicieron
primer inhibidor", xlab="Equipo / Ninguno", ylab = "Número de partidas",
        ylim = c(0,30000), col = c("White", "Blue", "Red"),
legend.text=firstinhib.qty$Var1)
```

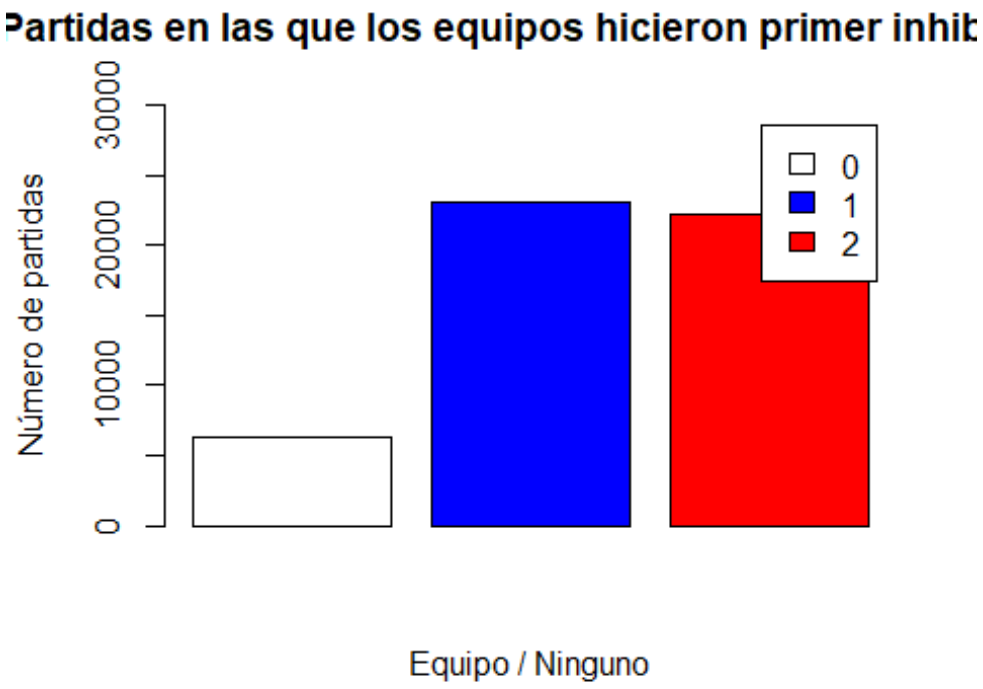


```
array.firstbaron <- c(firstbaron.qty[1, 2],firstbaron.qty[2, 2],
firstbaron.qty[3, 2])
barplot(array.firstbaron, main="Partidas en las que los equipos hicieron
primer barón", xlab="Equipo / Ninguno", ylab = "Número de partidas",
        ylim = c(0,30000), col = c("White", "Blue", "Red"),
legend.text=firstbaron.qty$Var1)
```

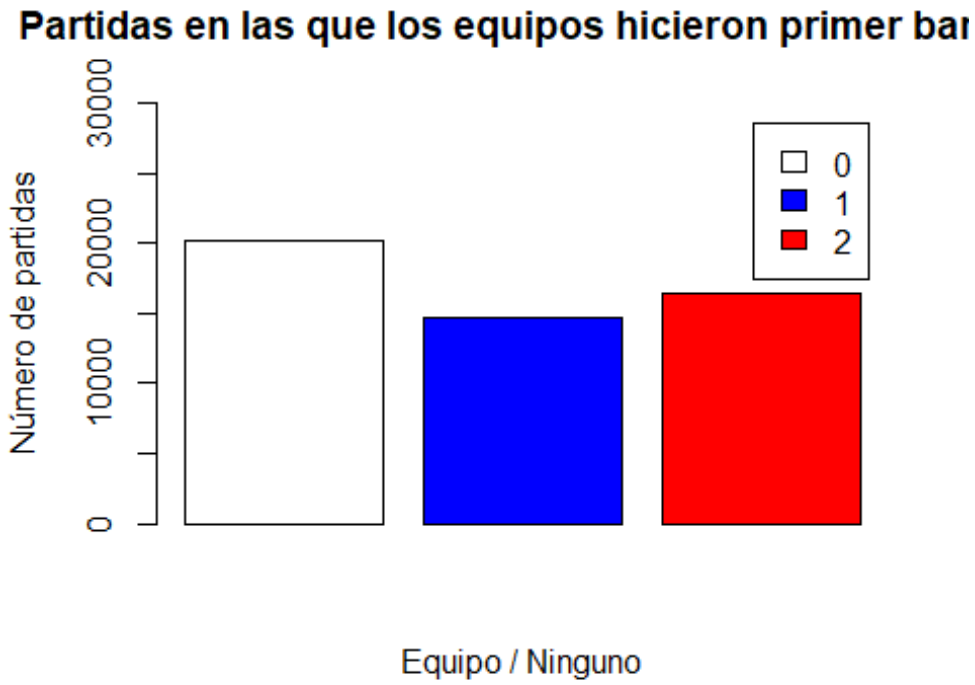


```
array.firstdragon <- c(firstdragon.qty[1, 2],firstdragon.qty[2, 2],
firstdragon.qty[3, 2])
barplot(array.firstdragon, main="Partidas en las que los equipos hicieron
primer dragón", xlab="Equipo / Ninguno", ylab = "Número de partidas",
        ylim = c(0,30000), col = c("White", "Blue", "Red"),
legend.text=firstdragon.qty$Var1)
```

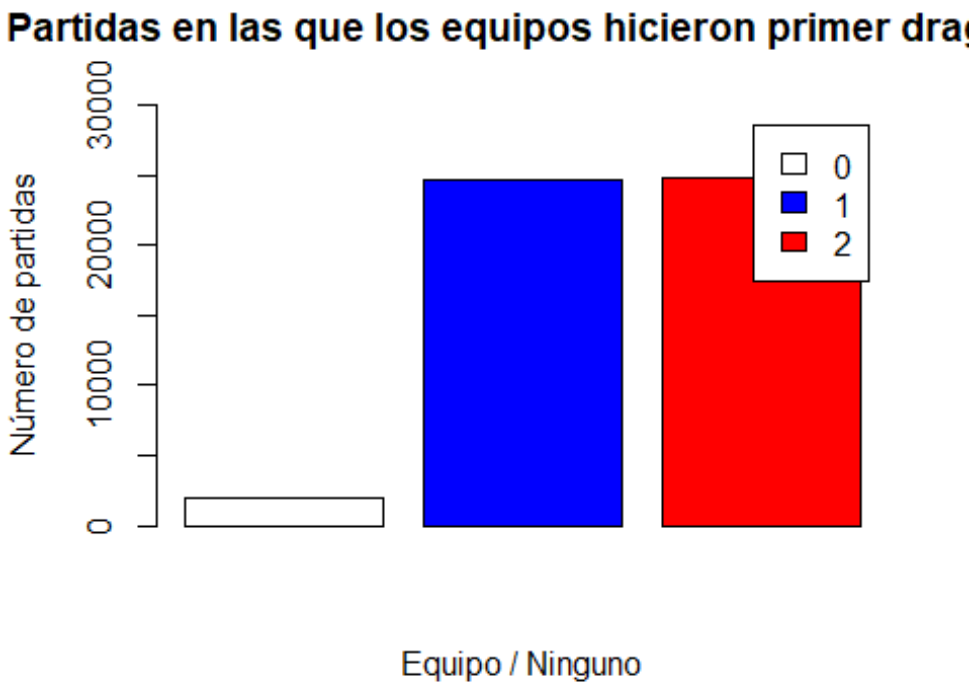


```
array.firstherald <- c(firstherald.qty[1, 2],firstherald.qty[2, 2],
firstherald.qty[3, 2])
barplot(array.firstherald, main="Partidas en las que los equipos hicieron
el heraldo", xlab="Equipo / Ninguno", ylab = "Número de partidas",
        ylim = c(0,30000), col = c("White", "Blue", "Red"),
legend.text=firstherald.qty$Var1)
```

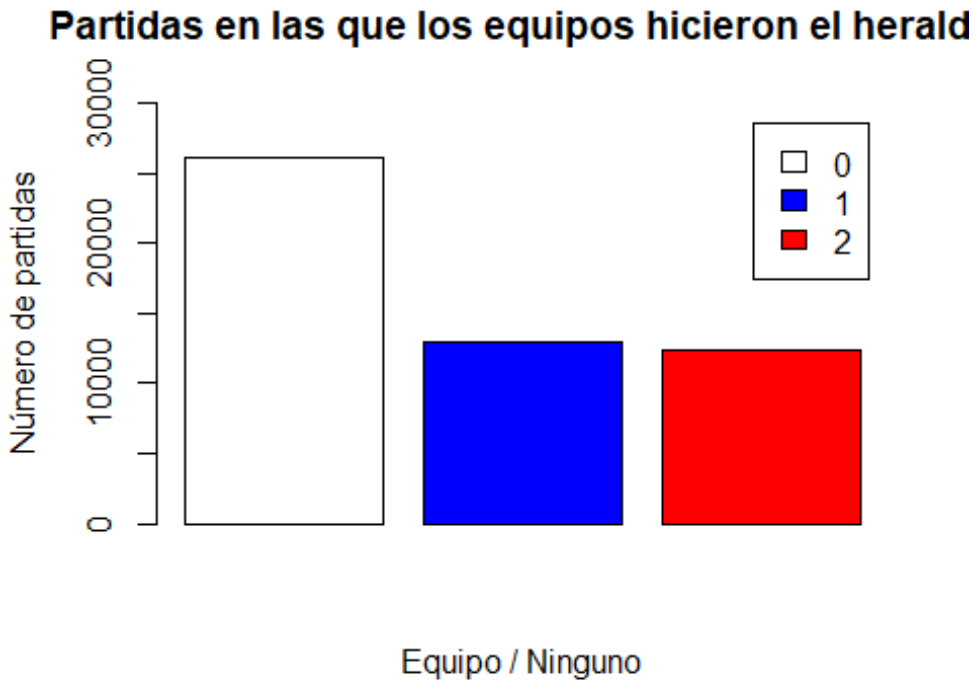

Si ponemos todos estos en orden cronológico a cuando suelen pasar, obtenemos lo siguiente:

```
dataframe.firstObjective <- cbind(array.firstblood, array.firsttower,
array.firstdragon, array.firstherald, array.firstinhib, array.firstbaron)
colnames(dataframe.firstObjective) <- c('FirstBlood', 'FirstTower',
'FirstDragon', 'FirstHerald', 'FirstInhib', 'FirstBaron')

colours = c("white","blue","red")

barplot(dataframe.firstObjective, main='Cantidad de primer objetivo de
cada tipo conseguido por los equipos',ylab='Veces', xlab='Evento',beside
= TRUE,
        col=colours, ylim=c(0,max(dataframe.firstObjective)*1.3))

box()
```

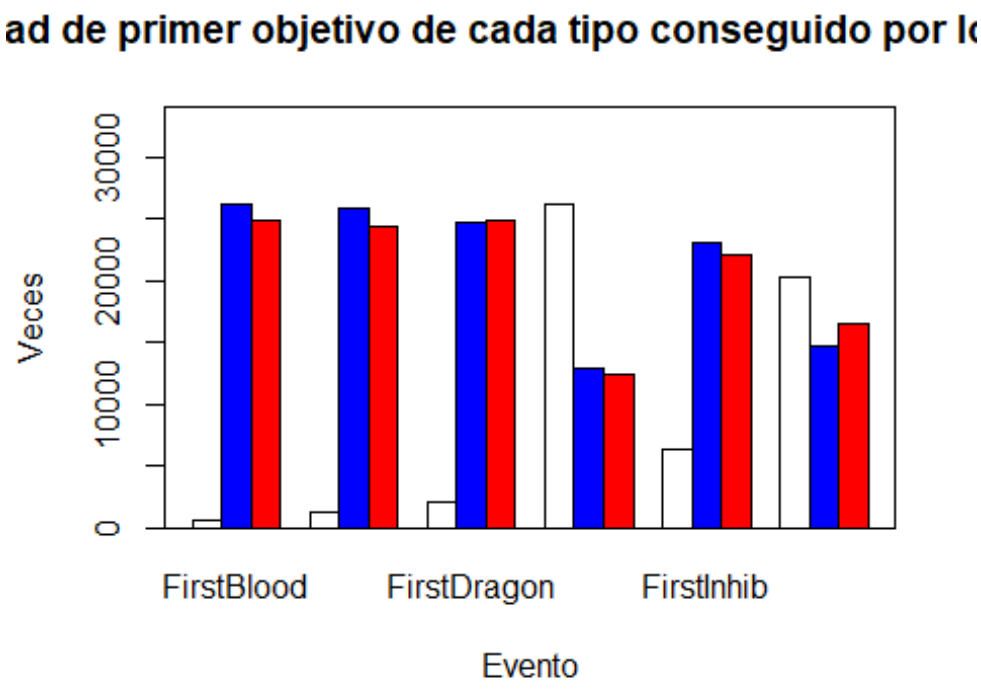

Exportamos a PDF este gráfico...

```
pdf("../imagenes/Barplot Cronología Partida FO.pdf")

barplot(dataframe.firstObjective, main='Cantidad de primer objetivo de
cada tipo conseguido por los equipos',ylab='Veces', xlab='Evento',beside
= TRUE,
        col=colours, ylim=c(0,max(dataframe.firstObjective)*1.3))

box()

dev.off
```

```
## function (which = dev.cur())
## {
##     if (which == 1)
##         stop("cannot shut down device 1 (the null device)")
##     .External(C_devoff, as.integer(which))
##     dev.cur()
## }
## <bytecode: 0x00000000134d26f0>
## <environment: namespace:grDevices>
```

Como podemos ver en los gráficos, la primera sangre y primera torre suelen caer un poco más del lado del equipo azul, siendo estos elementos que se dan al principio de la partida.

Respecto al primer dragón y el heraldo, que se dan en el medio de la partida, se igualan las tornas.

Sin embargo, con los objetivos de final de partida, como es el primer barón, es el equipo rojo quien lo suele conseguir. En cambio, el equipo azul suele conseguir con un poco más de frecuencia el primer inhibidor.

Machine Learning

Preparación datos machine learning

Dataset total

Ahora usaremos algoritmos de Machine Learning para ver si somos capaces de predecir quién va a ganar en base a una serie de características.

Para hacer esto, vamos a crear un dataset a partir de data.games solo para lo que va a ser el Machine Learning. En él, dejaré las variables que creo necesarias para la predicción de una partida y así usaremos este dataset, tras un centrado y escalado.

Creación del Dataset:

```
data.games.names <- inner_join(data.games, data.champs, by =
c("t1_champ1id" = "id"))
data.games.names <- inner_join(data.games.names, data.champs, by =
c("t1_champ2id" = "id"))
data.games.names <- inner_join(data.games.names, data.champs, by =
c("t1_champ3id" = "id"))
data.games.names <- inner_join(data.games.names, data.champs, by =
c("t1_champ4id" = "id"))
data.games.names <- inner_join(data.games.names, data.champs, by =
c("t1_champ5id" = "id"))
data.games.names <- inner_join(data.games.names, data.champs, by =
c("t2_champ1id" = "id"))
data.games.names <- inner_join(data.games.names, data.champs, by =
c("t2_champ2id" = "id"))
data.games.names <- inner_join(data.games.names, data.champs, by =
c("t2_champ3id" = "id"))
data.games.names <- inner_join(data.games.names, data.champs, by =
c("t2_champ4id" = "id"))
data.games.names <- inner_join(data.games.names, data.champs, by =
c("t2_champ5id" = "id"))

champs.names <- data.games.names[,62:71]
colnames(champs.names) <- c("P1T1", "P2T1", "P3T1", "P4T1", "P5T1",
"P1T2", "P2T2", "P3T2", "P4T2", "P5T2")


# Ahora paso todos los campeones a variables binarias. Esto hace que para
todas las predicciones no tenga que usar distancias ni categorías entre
```

```r
ellos, lo que me permite que sean más justas.

vectors_champs <- dummy_cols(champs.names)
vectors_champs <- vectors_champs[, -1:-10]

# Ahora lo único que tengo que hacer es crear el dataset final para el
machine learning, quitando aquellas variables que no deseo que estén
(entre ellas el código de los campeones) y añadiendo esta codificación
binaria que acabo de crear.

data.ml <- data.games[, c(-1, -2, -4, -13, -14, -16, -17, -19, -20, -22,
-23, -25, -26, -38, -39, -41, -42, -44, -45, -47, -48)]
data.ml <- data.ml[, -9:-13]
data.ml <- data.ml[, -19:-25]

# Ahora hago lo mismo de antes para los nombres pero con los bans. Antes
que nada, tengo que añadir None como la elección de ningún campeón para
banear en el df de campeones.

df.tonto <- data.frame("None", as.integer(1000))
names(df.tonto) <- c("name", "id")
data.champs <- rbind(data.champs, df.tonto)

data.games[data.games=="-1"]<-1000

data.games.bans <- inner_join(data.games, data.champs, by = c("t1_ban1" =
"id"))
data.games.bans <- inner_join(data.games.bans, data.champs, by =
c("t1_ban2" = "id"))
data.games.bans <- inner_join(data.games.bans, data.champs, by =
c("t1_ban3" = "id"))
data.games.bans <- inner_join(data.games.bans, data.champs, by =
c("t1_ban4" = "id"))
data.games.bans <- inner_join(data.games.bans, data.champs, by =
c("t1_ban5" = "id"))
data.games.bans <- inner_join(data.games.bans, data.champs, by =
c("t2_ban1" = "id"))
data.games.bans <- inner_join(data.games.bans, data.champs, by =
c("t2_ban2" = "id"))
data.games.bans <- inner_join(data.games.bans, data.champs, by =
c("t2_ban3" = "id"))
data.games.bans <- inner_join(data.games.bans, data.champs, by =
c("t2_ban4" = "id"))
data.games.bans <- inner_join(data.games.bans, data.champs, by =
c("t2_ban5" = "id"))

champs.bans.names <- data.games.bans[,62:71]
colnames(champs.bans.names) <- c("B1T1", "B2T1", "B3T1", "B4T1", "B5T1",
"B1T2", "B2T2", "B3T2", "B4T2", "B5T2")
```

```
vectors_champs.bans <- dummy_cols(champs.bans.names)
vectors_champs.bans <- vectors_champs.bans[, -1:-10]

# Finalmente, hago las últimas transformaciones y adiciones a data.ml
para obtener el resultado final

data.ml <- data.ml[, -14:-18]
data.ml <- data.ml[, -19:-23]

data.ml <- cbind(data.ml, vectors_champs, vectors_champs.bans)

# Finalmente,hago una segunda matriz sin el resultado, que será la que
centre y escale:

data.ml.centscal <- data.ml[, -2]
```

Ahora hacemos un centrado y escalado de los datos para evitar distorsionar la predicción:

```
preObjeto <- preProcess(data.ml.centscal, method=c("center", "scale"))  #
Quiero hacer un centrado y escalado
data.ml.centscal <- predict(preObjeto, data.ml.centscal)
```

Estos archivos son grandes, veamos su tamaño:

```
object_size(data.ml)

## 575 MB

object_size(data.ml.centscal)

## 1.15 GB

resultado.pca.ml <- PCA(data.ml.centscal, graph = FALSE)

#Con la siguiente línea podemos ver que podemos hacer con esto calculado
print(resultado.pca.ml)

## **Results for the Principal Component Analysis (PCA)**
## The analysis was performed on 51490 individuals, described by 2787
variables
## *The results are available in the following objects:
##
##    name               description
## 1  "$eig"             "eigenvalues"
## 2  "$var"             "results for the variables"
## 3  "$var$coord"       "coord. for the variables"
## 4  "$var$cor"         "correlations variables - dimensions"
## 5  "$var$cos2"        "cos2 for the variables"
```

```
## 6  "$var$contrib"     "contributions of the variables"
## 7  "$ind"             "results for the individuals"
## 8  "$ind$coord"       "coord. for the individuals"
## 9  "$ind$cos2"        "cos2 for the individuals"
## 10 "$ind$contrib"     "contributions of the individuals"
## 11 "$call"            "summary statistics"
## 12 "$call$centre"     "mean of the variables"
## 13 "$call$ecart.type" "standard error of the variables"
## 14 "$call$row.w"      "weights for the individuals"
## 15 "$call$col.w"      "weights for the variables"
```

Nos interesa ver los eigenvalues, que son los que presentarán la cantidad de varianza que aportan las variables:

```
eigenvalues.PCA.ml <- resultado.pca.ml$eig
head(eigenvalues.PCA.ml)
```

```
##        eigenvalue percentage of variance cumulative percentage of
variance
## comp 1   5.508868             0.19766300
0.1976630
## comp 2   3.274071             0.11747655
0.3151395
## comp 3   3.015903             0.10821324
0.4233528
## comp 4   1.994136             0.07155134
0.4949041
## comp 5   1.877788             0.06737667
0.5622808
## comp 6   1.833950             0.06580373
0.6280845
```

Como se puede comprobar, de las 24 variables (componentes) que tenemos, la mitad de la varianza la conseguimos con aproximadamente 5 variables. También se puede ver que a parti de las 17 variables prácticamente no hay un aumento de la varianza. En el caso de un problema grande, sería interesante la eliminación de algunas de las variables, para dejar un dataset más pequeño con el que poder trabajar. En nuestro caso, nuestro problema es pequeño, y además las variables están escogidas a mano, por lo que no haré una reducción del dataset.

Ahora, para completar este apartado de PCA, lo que voy a hacer es sacar la gráfica de la varianza acumulada con los valores anteriores:

```
plotPCA.ml <- fviz_screeplot(resultado.pca.ml, ncp=60)
plot(plotPCA.ml)
```

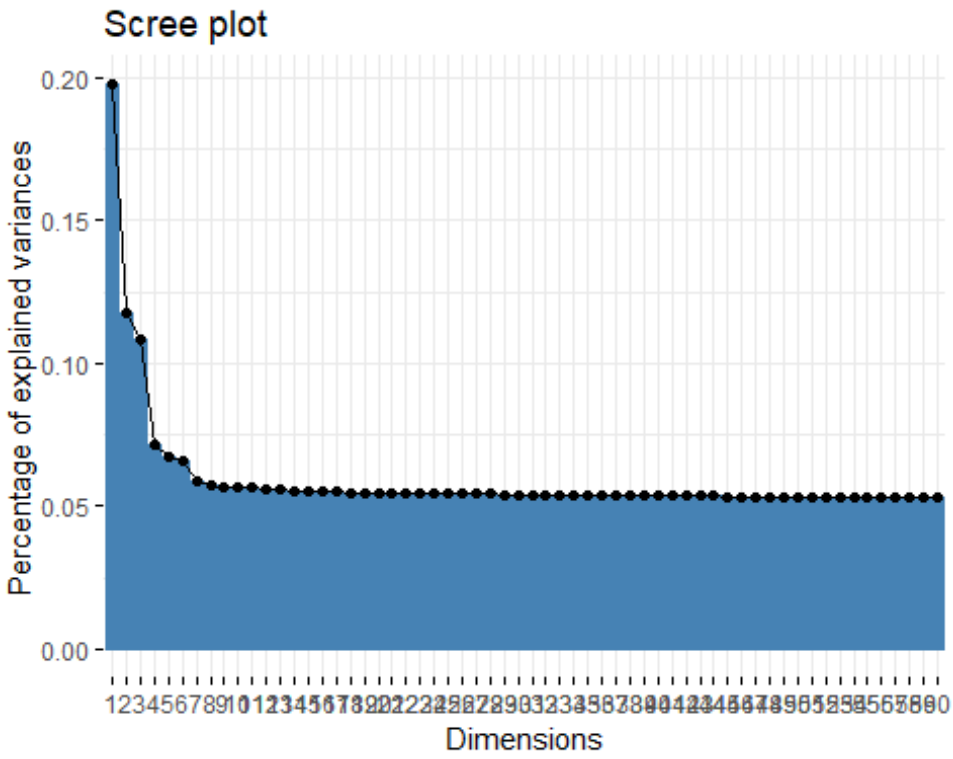

Exportamos a PDF...

```
pdf("../imagenes/PCATotal.pdf")
plot(plotPCA.ml)
dev.off
```

```
## function (which = dev.cur())
## {
##     if (which == 1)
##         stop("cannot shut down device 1 (the null device)")
##     .External(C_devoff, as.integer(which))
##     dev.cur()
## }
## <bytecode: 0x00000000134d26f0>
## <environment: namespace:grDevices>
```

Como vemos, todas las dimensiones van aportando su “granito de arena”, pero ninguna de ellas (según estamos viendo en las 60 primeras) deja de aportar un poco.

Si vamos al dataframe generado en eigenvalues.PCA.ml, vemos que hasta que no llegamos a las 2000 componentes principales no obtenemos al menos un 80% de explicación, mientras que hasta que no llegamos a unas pocas dimensiones del final no obtenemos la explicación completa. Por ello, no reduciré las dimensiones del dataframe, y trabajaremos con él a pesar de que sea más lento y pesado.

Dataset campeones

A partir del dataset total, voy a hacer un dataset solo con los campeones (ya codificados), de tal manera que se pueda predecir también solo por ellos:

```
data.ml.campeones <- data.ml[, 19:2788]

#matriz.sparse.campeones <- Matrix(data.ml.campeones, sparse = T)
```

Ahora, al igual que antes, calculamos el PCA:

```
resultado.pca.campeones.ml <- PCA(data.ml.campeones, graph = FALSE)

#Con la siguiente línea podemos ver que podemos hacer con esto calculado
print(resultado.pca.campeones.ml)
```

```
## **Results for the Principal Component Analysis (PCA)**
## The analysis was performed on 51490 individuals, described by 2770
variables
## *The results are available in the following objects:
##
##    name               description
## 1  "$eig"             "eigenvalues"
## 2  "$var"             "results for the variables"
## 3  "$var$coord"       "coord. for the variables"
## 4  "$var$cor"         "correlations variables - dimensions"
## 5  "$var$cos2"        "cos2 for the variables"
## 6  "$var$contrib"     "contributions of the variables"
## 7  "$ind"             "results for the individuals"
## 8  "$ind$coord"       "coord. for the individuals"
## 9  "$ind$cos2"        "cos2 for the individuals"
## 10 "$ind$contrib"     "contributions of the individuals"
## 11 "$call"            "summary statistics"
## 12 "$call$centre"     "mean of the variables"
## 13 "$call$ecart.type" "standard error of the variables"
## 14 "$call$row.w"      "weights for the individuals"
## 15 "$call$col.w"      "weights for the variables"
```

Nos interesa ver los eigenvalues, que son los que presentarán la cantidad de varianza que aportan las variables:

```
eigenvalues.PCA.campeones.ml <- resultado.pca.campeones.ml$eig
head(eigenvalues.PCA.campeones.ml)
```

```
##        eigenvalue percentage of variance cumulative percentage of
variance
## comp 1   3.181314             0.11484890
0.1148489
## comp 2   1.947903             0.07032139
0.1851703
## comp 3   1.839567             0.06641037
```

```
0.2515807
## comp 4   1.643525             0.05933303
0.3109137
## comp 5   1.598470             0.05770651
0.3686202
## comp 6   1.585067             0.05722264
0.4258428
```

Ahora, para completar este apartado de PCA, lo que voy a hacer es sacar la gráfica de la varianza acumulada con los valores anteriores:

```
plotPCA.campeones.ml <- fviz_screeplot(resultado.pca.campeones.ml,
ncp=60)
plot(plotPCA.campeones.ml)
```

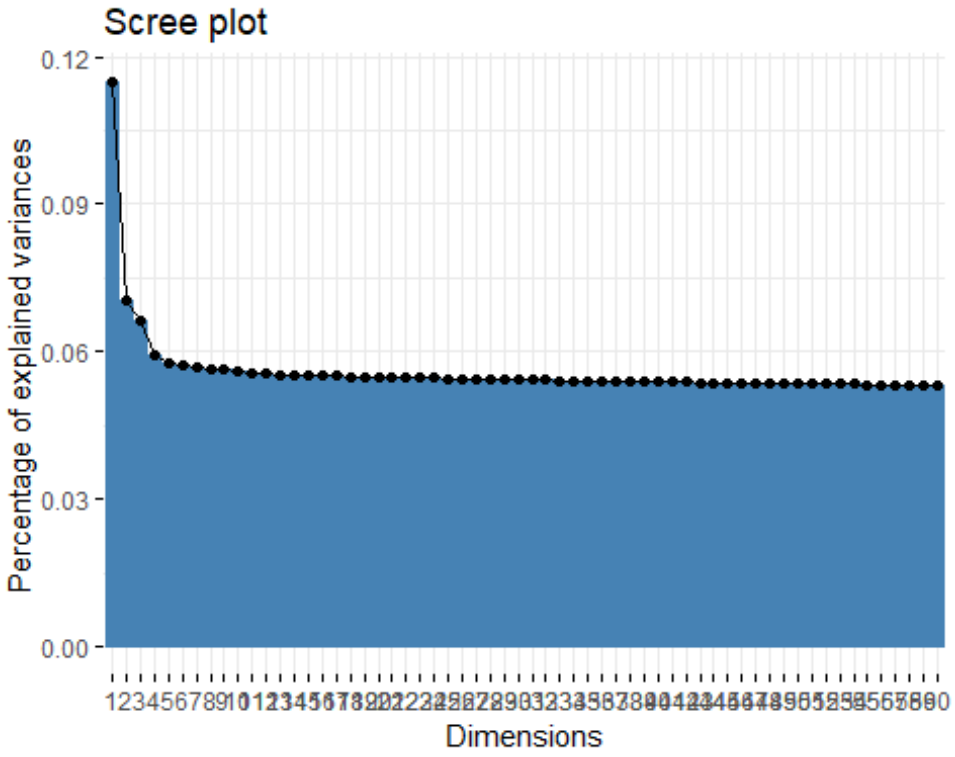

Exportamos a PDF...

```
pdf("../imagenes/PCACampones.pdf")
plot(plotPCA.campeones.ml)
dev.off

## function (which = dev.cur())
## {
##     if (which == 1)
##         stop("cannot shut down device 1 (the null device)")
##     .External(C_devoff, as.integer(which))
##     dev.cur()
## }
```

```
## <bytecode: 0x00000000134d26f0>
## <environment: namespace:grDevices>
```

Dataset datos equipos

A partir del dataset total, voy a hacer un dataset solo con las estadísticas de los equipos, de tal manera que se pueda predecir también solo por ellos, creando un dataset más pequeño. Con este dataset corroboraremos que no hacen falta los campeones para predecir el ganador de una partida, sino que con las estadísticas vale:

```
data.ml.stats.centscal <- data.ml[, 1:18]
data.ml.stats.centscal <- data.ml.stats.centscal[, -2] #Quitamos el
ganador

preObjeto.stats <- preProcess(data.ml.stats.centscal, method=c("center",
"scale"))  # Quiero hacer un centrado y escalado
data.ml.stats.centscal <- predict(preObjeto.stats,
data.ml.stats.centscal)
```

Ahora, al igual que antes, calculamos el PCA:

```
resultado.pca.stats.ml <- PCA(data.ml.stats.centscal, graph = FALSE)

#Con la siguiente línea podemos ver que podemos hacer con esto calculado
print(resultado.pca.stats.ml)

## **Results for the Principal Component Analysis (PCA)**
## The analysis was performed on 51490 individuals, described by 17
variables
## *The results are available in the following objects:
##
##    name               description
## 1  "$eig"             "eigenvalues"
## 2  "$var"             "results for the variables"
## 3  "$var$coord"       "coord. for the variables"
## 4  "$var$cor"         "correlations variables - dimensions"
## 5  "$var$cos2"        "cos2 for the variables"
## 6  "$var$contrib"     "contributions of the variables"
## 7  "$ind"             "results for the individuals"
## 8  "$ind$coord"       "coord. for the individuals"
## 9  "$ind$cos2"        "cos2 for the individuals"
## 10 "$ind$contrib"     "contributions of the individuals"
## 11 "$call"            "summary statistics"
## 12 "$call$centre"     "mean of the variables"
## 13 "$call$ecart.type" "standard error of the variables"
## 14 "$call$row.w"      "weights for the individuals"
## 15 "$call$col.w"      "weights for the variables"
```

Nos interesa ver los eigenvalues, que son los que presentarán la cantidad de varianza que aportan las variables:

```
eigenvalues.PCA.stats.ml <- resultado.pca.stats.ml$eig
head(eigenvalues.PCA.stats.ml)

##        eigenvalue percentage of variance cumulative percentage of
variance
## comp 1  5.4055231              31.797194
31.79719
## comp 2  2.9381181              17.283047
49.08024
## comp 3  1.7478086              10.281227
59.36147
## comp 4  1.3032125               7.665956
67.02743
## comp 5  1.0609948               6.241146
73.26857
## comp 6  0.9598527               5.646193
78.91476
```

Ahora, para completar este apartado de PCA, lo que voy a hacer es sacar la gráfica de la varianza acumulada con los valores anteriores:

```
plotPCA.stats.ml <- fviz_screeplot(resultado.pca.stats.ml, ncp=60)
plot(plotPCA.stats.ml)
```

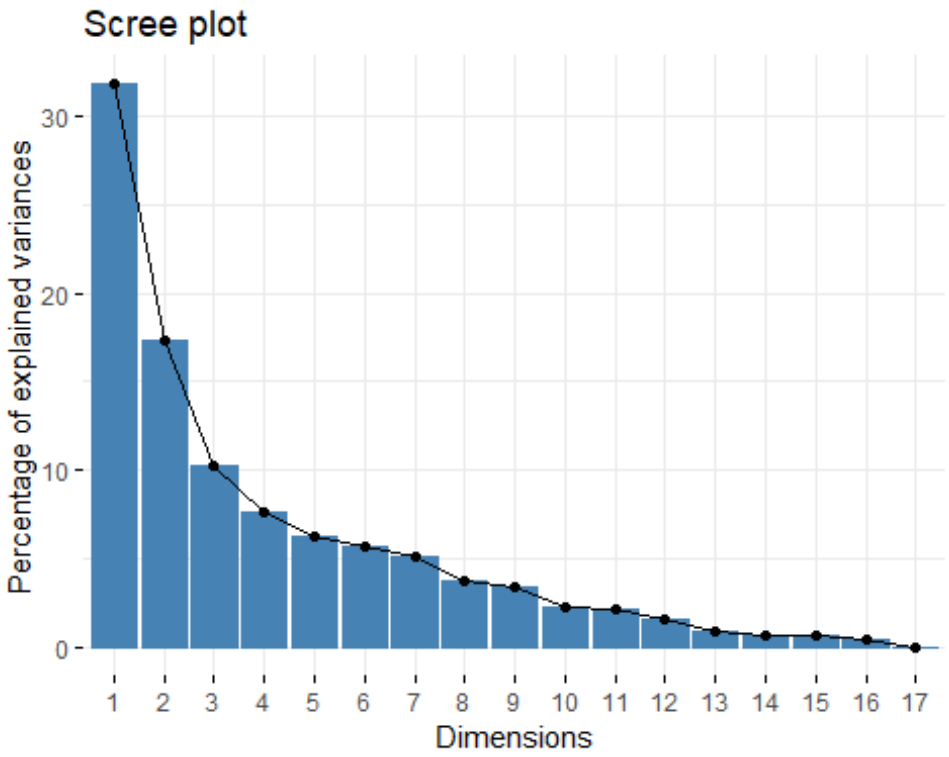

Exportamos a PDF:

```
pdf("../imagenes/PCAstatsML.pdf")
plot(plotPCA.stats.ml)
dev.off
```

```
## function (which = dev.cur())
## {
##     if (which == 1)
##         stop("cannot shut down device 1 (the null device)")
##     .External(C_devoff, as.integer(which))
##     dev.cur()
## }
## <bytecode: 0x00000000134d26f0>
## <environment: namespace:grDevices>
```

Algoritmos Supervisados

Pasamos ahora a una revisión / uso de algoritmos supervisados:

Perceptrón Multicapa

El algoritmo supervisado por el que siempre se debe de empezar es el perceptrón multicapa. Con este algoritmo de clasificación voy a intentar predecir el resultado de la partida. Este algoritmo se basa en una red neuronal con una capa intermedia (en este caso), mediante la cual podemos procesar datos más complejos que con un perceptrón monocapa. Con este algoritmo comprobaremos si las partidas ganadas por unos y por otros son linealmente separables.

Ahora vamos a importar la librería nnet, que nos sirve para hacer perceptrones

Ahora lo que hago es coger un conjunto muy grande de los datos para hacer el entrenamiento

```
conjuntoEntrenamiento <- sample(1:nrow(data.ml.stats.centscal), 45000)
```

Creo una tabla para guardar los resultados de todos los tests del perceptrón:

```
resultados.perceptron <- data.frame(stringsAsFactors=FALSE)
```

1 NEURONA
##
##
####

Lo que voy a hacer ahora es entrenar la red neuronal con diferente cantidad de neuronas,y voy a ir comparando el resultado...

SIN SOFTMAX ##############################

```
# Ahora creamos un dataframe para guardar los resultados de este bucle
```

```r
  dataframe.resultados.1neu <- data.frame(Ent_1neu=numeric(),
                                          Test_1neu=numeric())


for (i in 1:10)
{

  partidas.1neu <- nnet( data.ml.stats.centscal[conjuntoEntrenamiento, ],
class.ind( data.ml[conjuntoEntrenamiento, 2] ) , size=1, MaxNWts=10000 )

  #Una vez que lo tengo entrenado, lo que voy a hacer es calcular el
error tanto en el entrenamiento como en el test de cada uno

  partidas.prediccion.1neu <- predict( partidas.1neu,
data.ml.stats.centscal[conjuntoEntrenamiento, ], type="raw" )
  head(partidas.prediccion.1neu) # Vemos las probabilidades de
pertenencia de cada valor

  # Ahora que los tengo todos entrenados, Determinamos cual es la máxima,
es decir, la clase a la que hay que asignar los objetos

  partidas.prediccion.1neu.class <- apply( partidas.prediccion.1neu,
MARGIN=1, FUN='which.is.max')

  #Calculo el acierto

  acierto_ent_1neu<- sum( diag( table( partidas.prediccion.1neu.class,
data.ml[conjuntoEntrenamiento, 2] ) ) )/length(conjuntoEntrenamiento)

  ###### TEST


  partidas.prediccion.test.1neu <- predict( partidas.1neu,
data.ml.stats.centscal[-conjuntoEntrenamiento, ], type="raw" )

  partidas.prediccion.test.1neu.class <- apply(
partidas.prediccion.test.1neu, MARGIN=1, FUN='which.is.max')

  table( partidas.prediccion.test.1neu.class , data.ml[-
conjuntoEntrenamiento, 2] )

  acierto_test_1neu <- sum( diag( table(
partidas.prediccion.test.1neu.class, data.ml[-conjuntoEntrenamiento, 2] )
) )/(nrow(data.ml.stats.centscal) - length(conjuntoEntrenamiento))


  dataframe.pasada <- data.frame(Ent_1neu = acierto_ent_1neu,
                                 Test_1neu= acierto_test_1neu)
```

```
  dataframe.resultados.1neu <- rbind(dataframe.resultados.1neu,
dataframe.pasada)

}
```

```
## # weights:  22
## initial  value 22624.058812
## final  value 6181.000000
## converged
## # weights:  22
## initial  value 24270.958565
## final  value 6890.000000
## converged
## # weights:  22
## initial  value 23532.782814
## iter  10 value 16588.367589
## iter  20 value 4608.407544
## iter  30 value 3136.465372
## iter  40 value 2893.760131
## iter  50 value 2777.601658
## iter  60 value 2764.962892
## iter  70 value 2756.787408
## iter  80 value 2732.915189
## iter  90 value 2606.878365
## iter 100 value 2536.009578
## final  value 2536.009578
## stopped after 100 iterations
## # weights:  22
## initial  value 24916.275908
## final  value 7010.000000
## converged
## # weights:  22
## initial  value 24712.259295
## final  value 8022.000000
## converged
## # weights:  22
## initial  value 23357.287747
## final  value 6740.000000
## converged
## # weights:  22
## initial  value 25238.498469
## iter  10 value 20844.990310
## iter  20 value 14239.853032
## iter  30 value 11736.114364
## iter  40 value 11735.929529
## final  value 11735.925198
## converged
## # weights:  22
## initial  value 23843.508920
```

```
## iter  10 value 21222.773317
## iter  20 value 19094.370629
## iter  30 value 4045.096017
## iter  40 value 2908.033698
## iter  50 value 2768.815312
## iter  60 value 2610.484101
## iter  70 value 2443.713085
## iter  80 value 2395.373141
## iter  90 value 2393.512079
## iter 100 value 2388.370119
## final  value 2388.370119
## stopped after 100 iterations
## # weights:  22
## initial  value 26752.269442
## iter  10 value 17557.094154
## iter  20 value 10372.644981
## iter  30 value 3616.429771
## iter  40 value 2864.522622
## iter  50 value 2776.189433
## iter  60 value 2752.020118
## iter  70 value 2553.863206
## iter  80 value 2429.271913
## iter  90 value 2400.099475
## iter 100 value 2397.277640
## final  value 2397.277640
## stopped after 100 iterations
## # weights:  22
## initial  value 22273.335621
## iter  10 value 4796.182643
## iter  20 value 3975.519101
## iter  30 value 2945.847171
## iter  40 value 2884.143936
## iter  50 value 2853.314269
## iter  60 value 2817.775676
## iter  70 value 2612.629596
## iter  80 value 2454.271142
## iter  90 value 2394.048463
## iter 100 value 2393.540179
## final  value 2393.540179
## stopped after 100 iterations
```

Ahora le vamos a añadir softmax, a ver si mejoramos...

CON SOFTMAX ##############################

```
  dataframe.resultados.1neu.soft <- data.frame(Ent_1neu_soft=numeric(),
                                               Test_1neu_soft=numeric())


for (i in 1:10)
{
```

```r
  partidas.1neu.soft <- nnet(
data.ml.stats.centscal[conjuntoEntrenamiento, ], class.ind(
data.ml[conjuntoEntrenamiento, 2] ) , size=1, MaxNWts=10000, softmax = T
)

  #Una vez que lo tengo entrenado, lo que voy a hacer es calcular el
error tanto en el entrenamiento como en el test de cada uno

  partidas.prediccion.1neu.soft <- predict( partidas.1neu.soft,
data.ml.stats.centscal[conjuntoEntrenamiento, ], type="raw" )
  head(partidas.prediccion.1neu.soft) # Vemos las probabilidades de
pertenencia de cada valor

  # Ahora que los tengo todos entrenados, Determinamos cual es la máxima,
es decir, la clase a la que hay que asignar los objetos

  partidas.prediccion.1neu.class.soft <- apply(
partidas.prediccion.1neu.soft, MARGIN=1, FUN='which.is.max')

  #Calculo el acierto

  acierto_ent_1neu.soft <- sum( diag( table(
partidas.prediccion.1neu.class.soft, data.ml[conjuntoEntrenamiento, 2] )
) )/length(conjuntoEntrenamiento)

  ###### TEST


  partidas.prediccion.test.1neu.soft <- predict( partidas.1neu.soft,
data.ml.stats.centscal[-conjuntoEntrenamiento, ], type="raw" )

  partidas.prediccion.test.1neu.class.soft <- apply(
partidas.prediccion.test.1neu.soft, MARGIN=1, FUN='which.is.max')

  table( partidas.prediccion.test.1neu.class.soft , data.ml[-
conjuntoEntrenamiento, 2] )

  acierto_test_1neu.soft <- sum( diag( table(
partidas.prediccion.test.1neu.class.soft, data.ml[-conjuntoEntrenamiento,
2] ) ) )/(nrow(data.ml.stats.centscal) - length(conjuntoEntrenamiento))


  dataframe.pasada <- data.frame(Ent_1neu_soft = acierto_ent_1neu.soft,
                                 Test_1neu_soft= acierto_test_1neu.soft)

  dataframe.resultados.1neu.soft <- rbind(dataframe.resultados.1neu.soft,
dataframe.pasada)
```

```
}
```

```
## # weights:  22
## initial  value 31816.726187
## iter  10 value 14475.967039
## iter  20 value 10690.367838
## iter  30 value 6393.831649
## iter  40 value 4405.682130
## iter  50 value 4155.222079
## iter  60 value 4080.862234
## iter  70 value 4019.847012
## iter  80 value 4008.207516
## iter  90 value 4006.209295
## iter 100 value 4006.006107
## final  value 4006.006107
## stopped after 100 iterations
## # weights:  22
## initial  value 33822.029691
## iter  10 value 10268.302538
## iter  20 value 8085.934507
## iter  30 value 6011.807646
## iter  40 value 5247.854990
## iter  50 value 4744.767807
## iter  60 value 4615.021222
## iter  70 value 4110.074684
## iter  80 value 4034.643788
## iter  90 value 4014.032889
## iter 100 value 4012.078811
## final  value 4012.078811
## stopped after 100 iterations
## # weights:  22
## initial  value 36113.082520
## iter  10 value 12881.482872
## iter  20 value 10857.149555
## iter  30 value 4136.930195
## iter  40 value 4066.831087
## iter  50 value 4018.930820
## iter  60 value 4016.842523
## iter  70 value 4008.232813
## iter  80 value 4005.348458
## iter  90 value 4004.963521
## iter 100 value 4004.937929
## final  value 4004.937929
## stopped after 100 iterations
## # weights:  22
## initial  value 32588.945650
## iter  10 value 10056.351410
## iter  20 value 8016.455666
## iter  30 value 5892.037237
```

```
## iter  40 value 5803.419400
## iter  50 value 5760.425997
## iter  60 value 5601.676456
## iter  70 value 5132.525548
## iter  80 value 4298.783069
## iter  90 value 4057.524728
## iter 100 value 4043.319847
## final  value 4043.319847
## stopped after 100 iterations
## # weights:  22
## initial  value 31381.334309
## iter  10 value 13524.383510
## iter  20 value 9672.134108
## iter  30 value 6467.355767
## iter  40 value 5501.950444
## iter  50 value 5267.530332
## iter  60 value 4970.251349
## iter  70 value 4389.745900
## iter  80 value 4060.968240
## iter  90 value 4016.709834
## iter 100 value 4014.390713
## final  value 4014.390713
## stopped after 100 iterations
## # weights:  22
## initial  value 31001.651193
## iter  10 value 10667.094105
## iter  20 value 6733.643477
## iter  30 value 6229.668642
## iter  40 value 5652.452048
## iter  50 value 5404.264403
## iter  60 value 4693.037584
## iter  70 value 4182.563306
## iter  80 value 4039.298820
## iter  90 value 4035.888167
## iter 100 value 4016.224163
## final  value 4016.224163
## stopped after 100 iterations
## # weights:  22
## initial  value 31792.927376
## iter  10 value 24634.772383
## iter  20 value 16258.448683
## iter  30 value 6115.386545
## iter  40 value 5491.258644
## iter  50 value 5133.954578
## iter  60 value 4329.046186
## iter  70 value 4078.394846
## iter  80 value 4045.244304
## iter  90 value 4037.229347
## iter 100 value 4010.007029
## final  value 4010.007029
```

```
## stopped after 100 iterations
## # weights:  22
## initial  value 30324.597367
## iter  10 value 7947.166016
## iter  20 value 6042.995199
## iter  30 value 4261.063204
## iter  40 value 4132.137119
## iter  50 value 4051.628936
## iter  60 value 4040.288816
## iter  70 value 4009.016590
## iter  80 value 4005.828952
## iter  90 value 4005.253005
## iter 100 value 4005.217664
## final  value 4005.217664
## stopped after 100 iterations
## # weights:  22
## initial  value 36972.728209
## iter  10 value 10874.138232
## iter  20 value 7731.297850
## iter  30 value 7190.948647
## iter  40 value 7133.630057
## iter  50 value 7128.365499
## iter  60 value 7128.260841
## iter  70 value 7128.203107
## iter  80 value 7127.725915
## iter  90 value 7127.624189
## iter 100 value 6196.886284
## final  value 6196.886284
## stopped after 100 iterations
## # weights:  22
## initial  value 44488.986254
## iter  10 value 26886.948792
## iter  20 value 15124.538771
## iter  30 value 13105.825508
## iter  40 value 13039.503327
## iter  50 value 13015.929130
## iter  60 value 13013.954374
## final  value 13013.570178
## converged
```

2 NEURONAS
##
##
####

SIN SOFTMAX ##############################

```r
dataframe.resultados.2neu <- data.frame(Ent_2neu=numeric(),
                                        Test_2neu=numeric())


for (i in 1:10)
{

  partidas.2neu <- nnet( data.ml.stats.centscal[conjuntoEntrenamiento, ],
class.ind( data.ml[conjuntoEntrenamiento, 2] ) , size=2, MaxNWts=10000 )

  #Una vez que lo tengo entrenado, lo que voy a hacer es calcular el
error tanto en el entrenamiento como en el test de cada uno

  partidas.prediccion.2neu <- predict( partidas.2neu,
data.ml.stats.centscal[conjuntoEntrenamiento, ], type="raw" )
  head(partidas.prediccion.2neu) # Vemos las probabilidades de
pertenencia de cada valor

  # Ahora que los tengo todos entrenados, Determinamos cual es la máxima,
es decir, la clase a la que hay que asignar los objetos

  partidas.prediccion.2neu.class <- apply( partidas.prediccion.2neu,
MARGIN=1, FUN='which.is.max')

  #Calculo el acierto

  acierto_ent_2neu<- sum( diag( table( partidas.prediccion.2neu.class,
data.ml[conjuntoEntrenamiento, 2] ) ) )/length(conjuntoEntrenamiento)

  ###### TEST


  partidas.prediccion.test.2neu <- predict( partidas.2neu,
data.ml.stats.centscal[-conjuntoEntrenamiento, ], type="raw" )

  partidas.prediccion.test.2neu.class <- apply(
partidas.prediccion.test.2neu, MARGIN=1, FUN='which.is.max')

  table( partidas.prediccion.test.2neu.class , data.ml[-
conjuntoEntrenamiento, 2] )

  acierto_test_2neu <- sum( diag( table(
partidas.prediccion.test.2neu.class, data.ml[-conjuntoEntrenamiento, 2] )
) )/(nrow(data.ml.stats.centscal) - length(conjuntoEntrenamiento))


  dataframe.pasada <- data.frame(Ent_2neu = acierto_ent_2neu,
                                 Test_2neu= acierto_test_2neu)
```

```
  dataframe.resultados.2neu <- rbind(dataframe.resultados.2neu,
dataframe.pasada)

}
```

```
## # weights:  42
## initial  value 25840.155275
## iter  10 value 3462.236440
## iter  20 value 2971.302975
## iter  30 value 2840.223535
## iter  40 value 2623.760746
## iter  50 value 2431.622084
## iter  60 value 2399.762494
## iter  70 value 2332.511987
## iter  80 value 2327.238905
## iter  90 value 2325.564707
## iter 100 value 2272.367680
## final  value 2272.367680
## stopped after 100 iterations
## # weights:  42
## initial  value 24410.882799
## final  value 6953.000000
## converged
## # weights:  42
## initial  value 23305.646010
## final  value 6428.000000
## converged
## # weights:  42
## initial  value 24814.238623
## iter  10 value 3417.619475
## iter  20 value 3099.374072
## iter  30 value 2915.994053
## iter  40 value 2775.721252
## iter  50 value 2666.024718
## iter  60 value 2618.403962
## iter  70 value 2558.330571
## iter  80 value 2447.234402
## iter  90 value 2217.092527
## iter 100 value 2153.080556
## final  value 2153.080556
## stopped after 100 iterations
## # weights:  42
## initial  value 25995.675747
## final  value 6734.000000
## converged
## # weights:  42
## initial  value 24295.624589
## final  value 5626.000000
## converged
```

```
## # weights:  42
## initial  value 25130.035474
## final  value 7086.000000
## converged
## # weights:  42
## initial  value 24346.296602
## final  value 8398.000000
## converged
## # weights:  42
## initial  value 22369.187385
## final  value 6094.000000
## converged
## # weights:  42
## initial  value 22358.481312
## final  value 7580.000000
## converged
```

Ahora le vamos a añadir softmax, a ver si mejoramos...

CON SOFTMAX ##############################

```
dataframe.resultados.2neu.soft <- data.frame(Ent_2neu_soft=numeric(),
                                             Test_2neu_soft=numeric())

for (i in 1:10)
{

  partidas.2neu.soft <- nnet(
data.ml.stats.centscal[conjuntoEntrenamiento, ], class.ind(
data.ml[conjuntoEntrenamiento, 2] ) , size=2, MaxNWts=10000, softmax = T
)

  #Una vez que lo tengo entrenado, lo que voy a hacer es calcular el
error tanto en el entrenamiento como en el test de cada uno

  partidas.prediccion.2neu.soft <- predict( partidas.2neu.soft,
data.ml.stats.centscal[conjuntoEntrenamiento, ], type="raw" )
  head(partidas.prediccion.2neu.soft) # Vemos las probabilidades de
pertenencia de cada valor

  # Ahora que los tengo todos entrenados, Determinamos cual es la máxima,
es decir, la clase a la que hay que asignar los objetos

  partidas.prediccion.2neu.class.soft <- apply(
partidas.prediccion.2neu.soft, MARGIN=1, FUN='which.is.max')

  #Calculo el acierto

  acierto_ent_2neu.soft <- sum( diag( table(
partidas.prediccion.2neu.class.soft, data.ml[conjuntoEntrenamiento, 2] )
```

```
) )/length(conjuntoEntrenamiento)

  ###### TEST


  partidas.prediccion.test.2neu.soft <- predict( partidas.2neu.soft,
data.ml.stats.centscal[-conjuntoEntrenamiento, ], type="raw" )

  partidas.prediccion.test.2neu.class.soft <- apply(
partidas.prediccion.test.2neu.soft, MARGIN=1, FUN='which.is.max')

  table( partidas.prediccion.test.2neu.class.soft , data.ml[-
conjuntoEntrenamiento, 2] )

  acierto_test_2neu.soft <- sum( diag( table(
partidas.prediccion.test.2neu.class.soft, data.ml[-conjuntoEntrenamiento,
2] ) ) )/(nrow(data.ml.stats.centscal) - length(conjuntoEntrenamiento))


  dataframe.pasada <- data.frame(Ent_2neu_soft = acierto_ent_2neu.soft,
                                 Test_2neu_soft= acierto_test_2neu.soft)

  dataframe.resultados.2neu.soft <- rbind(dataframe.resultados.2neu.soft,
dataframe.pasada)

}

## # weights:  42
## initial  value 35604.385568
## iter  10 value 7797.312783
## iter  20 value 5489.874705
## iter  30 value 4600.353133
## iter  40 value 3858.241601
## iter  50 value 3718.072566
## iter  60 value 3601.936007
## iter  70 value 3419.934162
## iter  80 value 3351.017232
## iter  90 value 3304.805955
## iter 100 value 3264.055832
## final  value 3264.055832
## stopped after 100 iterations
## # weights:  42
## initial  value 40089.329036
## iter  10 value 7464.682074
## iter  20 value 4899.671253
## iter  30 value 3817.568606
## iter  40 value 3694.252237
## iter  50 value 3641.872475
## iter  60 value 3624.033958
```

```
## iter  70 value 3608.045789
## iter  80 value 3580.369062
## iter  90 value 3523.513787
## iter 100 value 3501.173999
## final  value 3501.173999
## stopped after 100 iterations
## # weights:  42
## initial  value 33335.693682
## iter  10 value 10351.140745
## iter  20 value 7091.200000
## iter  30 value 4335.461190
## iter  40 value 3787.079278
## iter  50 value 3540.812141
## iter  60 value 3407.405179
## iter  70 value 3241.111270
## iter  80 value 3201.161583
## iter  90 value 3185.168782
## iter 100 value 3150.300766
## final  value 3150.300766
## stopped after 100 iterations
## # weights:  42
## initial  value 30535.698127
## iter  10 value 5520.475183
## iter  20 value 4221.312998
## iter  30 value 3960.053049
## iter  40 value 3826.261310
## iter  50 value 3501.797552
## iter  60 value 3325.549701
## iter  70 value 3214.095206
## iter  80 value 3190.431762
## iter  90 value 3160.363801
## iter 100 value 3157.437492
## final  value 3157.437492
## stopped after 100 iterations
## # weights:  42
## initial  value 32916.433268
## iter  10 value 5909.153652
## iter  20 value 5435.668208
## iter  30 value 4919.805738
## iter  40 value 3971.840421
## iter  50 value 3490.495592
## iter  60 value 3336.246843
## iter  70 value 3303.083843
## iter  80 value 3298.597854
## iter  90 value 3297.486332
## iter 100 value 3294.903849
## final  value 3294.903849
## stopped after 100 iterations
## # weights:  42
## initial  value 30538.171685
```

```
## iter  10 value 6985.931956
## iter  20 value 5861.761104
## iter  30 value 5123.162615
## iter  40 value 4434.213353
## iter  50 value 4014.854854
## iter  60 value 3871.153838
## iter  70 value 3762.017066
## iter  80 value 3596.754797
## iter  90 value 3408.249413
## iter 100 value 3400.812859
## final  value 3400.812859
## stopped after 100 iterations
## # weights:  42
## initial  value 35823.723028
## iter  10 value 7485.770023
## iter  20 value 6279.273730
## iter  30 value 5671.718186
## iter  40 value 5515.298405
## iter  50 value 5039.290622
## iter  60 value 4041.590538
## iter  70 value 3917.048914
## iter  80 value 3735.395832
## iter  90 value 3634.636187
## iter 100 value 3585.316572
## final  value 3585.316572
## stopped after 100 iterations
## # weights:  42
## initial  value 41867.338103
## iter  10 value 5394.414477
## iter  20 value 5021.610778
## iter  30 value 4386.463230
## iter  40 value 4150.124830
## iter  50 value 3735.517136
## iter  60 value 3296.987658
## iter  70 value 3237.298387
## iter  80 value 3225.560874
## iter  90 value 3221.499831
## iter 100 value 3219.043576
## final  value 3219.043576
## stopped after 100 iterations
## # weights:  42
## initial  value 33021.086483
## iter  10 value 11951.794569
## iter  20 value 5951.778205
## iter  30 value 4289.164513
## iter  40 value 3888.187929
## iter  50 value 3630.558637
## iter  60 value 3588.242435
## iter  70 value 3520.729023
## iter  80 value 3345.856865
```

```
## iter  90 value 3237.972547
## iter 100 value 3203.517510
## final  value 3203.517510
## stopped after 100 iterations
## # weights:  42
## initial  value 29993.757351
## iter  10 value 5089.251255
## iter  20 value 4638.809249
## iter  30 value 4012.342598
## iter  40 value 3581.140725
## iter  50 value 3255.324719
## iter  60 value 3219.136036
## iter  70 value 3213.213024
## iter  80 value 3200.152059
## iter  90 value 3166.323502
## iter 100 value 3161.552976
## final  value 3161.552976
## stopped after 100 iterations
```

3 NEURONAS
##
##
####

SIN SOFTMAX ##############################

```
dataframe.resultados.3neu <- data.frame(Ent_3neu=numeric(),
                                        Test_3neu=numeric())


for (i in 1:10)
{

  partidas.3neu <- nnet( data.ml.stats.centscal[conjuntoEntrenamiento, ],
class.ind( data.ml[conjuntoEntrenamiento, 2] ) , size=3, MaxNWts=10000 )

  #Una vez que lo tengo entrenado, lo que voy a hacer es calcular el
error tanto en el entrenamiento como en el test de cada uno

  partidas.prediccion.3neu <- predict( partidas.2neu,
data.ml.stats.centscal[conjuntoEntrenamiento, ], type="raw" )
  head(partidas.prediccion.3neu) # Vemos las probabilidades de
pertenencia de cada valor

  # Ahora que los tengo todos entrenados, Determinamos cual es la máxima,
es decir, la clase a la que hay que asignar los objetos

  partidas.prediccion.3neu.class <- apply( partidas.prediccion.3neu,
```

```
MARGIN=1, FUN='which.is.max')

  #Calculo el acierto

  acierto_ent_3neu<- sum( diag( table( partidas.prediccion.3neu.class,
data.ml[conjuntoEntrenamiento, 2] ) ) )/length(conjuntoEntrenamiento)

  ###### TEST


  partidas.prediccion.test.3neu <- predict( partidas.3neu,
data.ml.stats.centscal[-conjuntoEntrenamiento, ], type="raw" )

  partidas.prediccion.test.3neu.class <- apply(
partidas.prediccion.test.3neu, MARGIN=1, FUN='which.is.max')

  table( partidas.prediccion.test.3neu.class , data.ml[-
conjuntoEntrenamiento, 2] )

  acierto_test_3neu <- sum( diag( table(
partidas.prediccion.test.3neu.class, data.ml[-conjuntoEntrenamiento, 2] )
) )/(nrow(data.ml.stats.centscal) - length(conjuntoEntrenamiento))


  dataframe.pasada <- data.frame(Ent_3neu = acierto_ent_3neu,
                                 Test_3neu= acierto_test_3neu)

  dataframe.resultados.3neu <- rbind(dataframe.resultados.3neu,
dataframe.pasada)

}
```

```
## # weights:  62
## initial  value 26828.271214
## final  value 6561.000000
## converged
## # weights:  62
## initial  value 22710.511207
## final  value 6332.000000
## converged
## # weights:  62
## initial  value 24379.179027
## final  value 8827.000000
## converged
## # weights:  62
## initial  value 25541.481209
## iter  10 value 4619.181129
## iter  20 value 3174.003482
## iter  30 value 2917.952079
```

```
## iter  40 value 2838.391520
## iter  50 value 2768.978140
## iter  60 value 2738.194913
## iter  70 value 2725.334110
## iter  80 value 2714.512227
## iter  90 value 2703.141973
## iter 100 value 2655.979968
## final  value 2655.979968
## stopped after 100 iterations
## # weights:  62
## initial  value 22170.705849
## final  value 8972.000000
## converged
## # weights:  62
## initial  value 26709.960284
## final  value 6654.000000
## converged
## # weights:  62
## initial  value 24253.079436
## iter  10 value 3320.514031
## iter  20 value 2579.013343
## iter  30 value 2360.935981
## iter  40 value 2190.891766
## iter  50 value 2050.066856
## iter  60 value 1912.612185
## iter  70 value 1788.640152
## iter  80 value 1779.507364
## iter  90 value 1766.816060
## iter 100 value 1740.566980
## final  value 1740.566980
## stopped after 100 iterations
## # weights:  62
## initial  value 26042.886570
## final  value 7092.000000
## converged
## # weights:  62
## initial  value 23050.440340
## final  value 7348.998780
## converged
## # weights:  62
## initial  value 21612.762762
## final  value 8415.000000
## converged
```

Ahora le vamos a añadir softmax, a ver si mejoramos...

CON SOFTMAX ##############################

```
dataframe.resultados.3neu.soft <- data.frame(Ent_3neu_soft=numeric(),
                                             Test_3neu_soft=numeric())
```

```r
for (i in 1:10)
{

  partidas.3neu.soft <- nnet(
data.ml.stats.centscal[conjuntoEntrenamiento, ], class.ind(
data.ml[conjuntoEntrenamiento, 2] ) , size=3, MaxNWts=10000, softmax = T
)

  #Una vez que lo tengo entrenado, lo que voy a hacer es calcular el
error tanto en el entrenamiento como en el test de cada uno

  partidas.prediccion.3neu.soft <- predict( partidas.3neu.soft,
data.ml.stats.centscal[conjuntoEntrenamiento, ], type="raw" )
  head(partidas.prediccion.3neu.soft) # Vemos las probabilidades de
pertenencia de cada valor

  # Ahora que los tengo todos entrenados, Determinamos cual es la máxima,
es decir, la clase a la que hay que asignar los objetos

  partidas.prediccion.3neu.class.soft <- apply(
partidas.prediccion.3neu.soft, MARGIN=1, FUN='which.is.max')

  #Calculo el acierto

  acierto_ent_3neu.soft <- sum( diag( table(
partidas.prediccion.3neu.class.soft, data.ml[conjuntoEntrenamiento, 2] )
) )/length(conjuntoEntrenamiento)

  ###### TEST


  partidas.prediccion.test.3neu.soft <- predict( partidas.3neu.soft,
data.ml.stats.centscal[-conjuntoEntrenamiento, ], type="raw" )

  partidas.prediccion.test.3neu.class.soft <- apply(
partidas.prediccion.test.3neu.soft, MARGIN=1, FUN='which.is.max')

  table( partidas.prediccion.test.3neu.class.soft , data.ml[-
conjuntoEntrenamiento, 2] )

  acierto_test_3neu.soft <- sum( diag( table(
partidas.prediccion.test.3neu.class.soft, data.ml[-conjuntoEntrenamiento,
2] ) ) )/(nrow(data.ml.stats.centscal) - length(conjuntoEntrenamiento))


  dataframe.pasada <- data.frame(Ent_3neu_soft = acierto_ent_3neu.soft,
                                 Test_3neu_soft= acierto_test_3neu.soft)

  dataframe.resultados.3neu.soft <- rbind(dataframe.resultados.3neu.soft,
```

```
dataframe.pasada)

}
```

```
## # weights:  62
## initial  value 26959.089071
## iter  10 value 8017.722062
## iter  20 value 5247.084761
## iter  30 value 4480.312728
## iter  40 value 3738.448424
## iter  50 value 3220.183428
## iter  60 value 3138.615727
## iter  70 value 3114.822323
## iter  80 value 3058.338077
## iter  90 value 3022.726137
## iter 100 value 3010.491971
## final  value 3010.491971
## stopped after 100 iterations
## # weights:  62
## initial  value 35104.216370
## iter  10 value 6483.391417
## iter  20 value 4890.381725
## iter  30 value 3968.377257
## iter  40 value 3601.383196
## iter  50 value 3508.332126
## iter  60 value 3475.916504
## iter  70 value 3391.964488
## iter  80 value 3261.791968
## iter  90 value 3223.394021
## iter 100 value 3205.021132
## final  value 3205.021132
## stopped after 100 iterations
## # weights:  62
## initial  value 38819.214037
## iter  10 value 5697.972041
## iter  20 value 4619.666363
## iter  30 value 3973.983565
## iter  40 value 3583.608368
## iter  50 value 3436.358579
## iter  60 value 3328.733748
## iter  70 value 3267.598449
## iter  80 value 3193.519942
## iter  90 value 3108.954612
## iter 100 value 2980.679935
## final  value 2980.679935
## stopped after 100 iterations
## # weights:  62
## initial  value 32039.077781
## iter  10 value 8111.232504
## iter  20 value 5420.802081
```

```
## iter  30 value 4498.438231
## iter  40 value 4148.657430
## iter  50 value 3878.581177
## iter  60 value 3401.912300
## iter  70 value 3227.973492
## iter  80 value 3204.279078
## iter  90 value 3184.520300
## iter 100 value 3173.132897
## final  value 3173.132897
## stopped after 100 iterations
## # weights:  62
## initial  value 37445.206609
## iter  10 value 5429.092585
## iter  20 value 3764.653607
## iter  30 value 3526.272064
## iter  40 value 3306.733051
## iter  50 value 3190.179832
## iter  60 value 3100.887719
## iter  70 value 3046.700525
## iter  80 value 3023.441888
## iter  90 value 3005.822905
## iter 100 value 2998.888772
## final  value 2998.888772
## stopped after 100 iterations
## # weights:  62
## initial  value 31287.984196
## iter  10 value 6079.603646
## iter  20 value 4570.149188
## iter  30 value 4181.983314
## iter  40 value 3598.110568
## iter  50 value 3421.396713
## iter  60 value 3286.008783
## iter  70 value 3240.871874
## iter  80 value 3218.348962
## iter  90 value 3204.576101
## iter 100 value 3175.740184
## final  value 3175.740184
## stopped after 100 iterations
## # weights:  62
## initial  value 26794.949255
## iter  10 value 5598.110012
## iter  20 value 4965.015483
## iter  30 value 4518.894922
## iter  40 value 3807.394313
## iter  50 value 3378.427630
## iter  60 value 3213.194834
## iter  70 value 3142.592053
## iter  80 value 3118.792102
## iter  90 value 3086.087949
## iter 100 value 3063.909032
```

```
## final  value 3063.909032
## stopped after 100 iterations
## # weights:  62
## initial  value 43440.447467
## iter  10 value 6455.955135
## iter  20 value 4470.867065
## iter  30 value 3853.774463
## iter  40 value 3486.695031
## iter  50 value 3340.582315
## iter  60 value 3268.582376
## iter  70 value 3214.993962
## iter  80 value 3172.211745
## iter  90 value 3093.484534
## iter 100 value 3079.523242
## final  value 3079.523242
## stopped after 100 iterations
## # weights:  62
## initial  value 31239.769360
## iter  10 value 4538.710585
## iter  20 value 4098.457931
## iter  30 value 3893.657551
## iter  40 value 3639.215430
## iter  50 value 3477.540030
## iter  60 value 3300.690772
## iter  70 value 3242.672931
## iter  80 value 3223.189747
## iter  90 value 3217.711392
## iter 100 value 3193.486925
## final  value 3193.486925
## stopped after 100 iterations
## # weights:  62
## initial  value 31241.236305
## iter  10 value 6771.217635
## iter  20 value 5290.205634
## iter  30 value 3872.584140
## iter  40 value 3542.170314
## iter  50 value 3353.494019
## iter  60 value 3184.756445
## iter  70 value 3120.444182
## iter  80 value 3007.669120
## iter  90 value 2951.047729
## iter 100 value 2936.044283
## final  value 2936.044283
## stopped after 100 iterations
```

Ahora juntamos todos los resultados:

```
dataframe.resultados.perceptron.stats <- cbind(dataframe.resultados.1neu,

dataframe.resultados.1neu.soft,
```

```
                                                dataframe.resultados.2neu,
dataframe.resultados.2neu.soft,
                                                dataframe.resultados.3neu,
dataframe.resultados.3neu.soft)

remove(dataframe.resultados.1neu)
remove(dataframe.resultados.1neu.soft)
remove(dataframe.resultados.2neu)
remove(dataframe.resultados.2neu.soft)
remove(dataframe.resultados.3neu)
remove(dataframe.resultados.3neu.soft)
```

Ahora, con estos resultados en el dataframe, vamos a ver los mejores resultados que he obtenido con cada red neuronal:

```
head(dataframe.resultados.perceptron.stats[order(dataframe.resultados.per
ceptron.stats$Test_1neu, decreasing = TRUE), 1:2])
```

```
##     Ent_1neu Test_1neu
## 8  0.9634222 0.9630200
## 9  0.9616444 0.9607088
## 10 0.9615778 0.9605547
## 3  0.9621111 0.9604006
## 1  0.9313111 0.9289676
## 2  0.9234444 0.9208012
```

```
head(dataframe.resultados.perceptron.stats[order(dataframe.resultados.per
ceptron.stats$Test_1neu_soft, decreasing = TRUE), 3:4])
```

```
##   Ent_1neu_soft Test_1neu_soft
## 1     0.9616444      0.9610169
## 6     0.9616667      0.9610169
## 2     0.9617333      0.9608629
## 3     0.9615556      0.9608629
## 5     0.9616667      0.9608629
## 7     0.9615778      0.9608629
```

```
head(dataframe.resultados.perceptron.stats[order(dataframe.resultados.per
ceptron.stats$Test_2neu, decreasing = TRUE), 5:6])
```

```
##    Ent_2neu Test_2neu
## 4 0.9665333 0.9627119
## 1 0.9645556 0.9620955
## 6 0.9374889 0.9354391
## 9 0.9321556 0.9326656
## 3 0.9285778 0.9246533
## 5 0.9251778 0.9228043
```

```
head(dataframe.resultados.perceptron.stats[order(dataframe.resultados.per
ceptron.stats$Test_2neu_soft, decreasing = TRUE), 7:8])
```

```
##    Ent_2neu_soft Test_2neu_soft
## 3      0.9694444      0.9676425
## 9      0.9684222      0.9667180
## 4      0.9691333      0.9662558
## 8      0.9678222      0.9656394
## 5      0.9674000      0.9648690
## 10     0.9668889      0.9630200
```

```
head(dataframe.resultados.perceptron.stats[order(dataframe.resultados.per
ceptron.stats$Test_3neu, decreasing = TRUE), 9:10])
```

```
##    Ent_3neu Test_3neu
## 7 0.9157778 0.9694915
## 4 0.9157778 0.9616333
## 2 0.9157778 0.9280431
## 1 0.9157778 0.9235747
## 6 0.9157778 0.9228043
## 8 0.9157778 0.9163328
```

```
head(dataframe.resultados.perceptron.stats[order(dataframe.resultados.per
ceptron.stats$Test_3neu_soft, decreasing = TRUE), 11:12])
```

```
##    Ent_3neu_soft Test_3neu_soft
## 10     0.9711111      0.9704160
## 5      0.9702222      0.9687211
## 3      0.9705778      0.9684129
## 7      0.9692444      0.9677966
## 4      0.9690444      0.9671803
## 8      0.9691556      0.9670262
```

Como podemos ver, el mejor resultado lo obtenemos con 3 neuronas y softmax, pero no difiere prácticamente nada con 1 neurona o 2 neuronas. De este modo, ante la igualdad de condiciones, la mejor red es la más simple, y por lo tanto la de 1 neurona.

KNN

K - Nearest Neighbours es otro algoritmo de clasificación muy utilizado. Se basa en la posición del nodo que se está analizando con los K nodos más cercanos mediante distancia euclídea. De este modo, calcula la similitud e indentifica a un nodo como de un grupo o de otro.

La teoría dice que para K-NN, el mejor número a escoger es la raíz cuadrada del total de observaciones que tenemos. Lo calculamos:

```
k <- round(sqrt(nrow(data.ml.stats.centscal)), 0)
```

Ahora creamos los grupos:

```
conjuntoEntrenamiento <- data.ml.stats.centscal[1:45000, ]
conjuntoTest <- data.ml.stats.centscal[45001 :
nrow(data.ml.stats.centscal), ] # Utilizo por supuesto la matriz de
centrado y escalado
```

```
etiquetasEntrenamiento <- data.ml[1:45000, 2]
etiquetasTest <- data.ml[45001:nrow(data.ml.stats.centscal), 2]
```

Ahora lo que vamos a hacer es calcular para diferentes K's el resultado que obtenemos, para ver qué tal clasifica:

```
K = 227
prediccion.knn.227 <- knn(train = conjuntoEntrenamiento,
                          test = conjuntoTest,
                          cl = etiquetasEntrenamiento,
                          k = 227)
head(prediccion.knn.227)
```

```
## [1] 2 2 1 1 1 2
## Levels: 1 2
```

Sacamos crosstable:

```
CrossTable(x = etiquetasTest ,
           y = prediccion.knn.227,
           prop.chisq = FALSE)
```

```
##
##
##    Cell Contents
## |-------------------------|
## |                       N |
## |           N / Row Total |
## |           N / Col Total |
## |         N / Table Total |
## |-------------------------|
##
##
## Total Observations in Table:  6490
##
##
##                | prediccion.knn.227
## etiquetasTest |         1 |         2 | Row Total |
## --------------|-----------|-----------|-----------|
##             1 |      3098 |       156 |      3254 |
##               |     0.952 |     0.048 |     0.501 |
##               |     0.948 |     0.048 |           |
##               |     0.477 |     0.024 |           |
## --------------|-----------|-----------|-----------|
##             2 |       170 |      3066 |      3236 |
##               |     0.053 |     0.947 |     0.499 |
##               |     0.052 |     0.952 |           |
##               |     0.026 |     0.472 |           |
## --------------|-----------|-----------|-----------|
##  Column Total |      3268 |      3222 |      6490 |
```

```
##                |     0.504 |     0.496 |           |
## --------------|-----------|-----------|-----------|
##
##
```

Ahora voy a hacer lo mismo con 150 y con 350, para ver las diferencias que puede haber con la predicción:

K = 150

```
prediccion.knn.150 <- knn(train = conjuntoEntrenamiento,
                          test = conjuntoTest,
                          cl = etiquetasEntrenamiento,
                          prob = TRUE,
                          k = 150)
head(prediccion.knn.150)
```

```
## [1] 2 2 1 1 1 2
## Levels: 1 2
```

Sacamos crosstable:

```
CrossTable(x = etiquetasTest ,
           y = prediccion.knn.150,
           prop.chisq = FALSE)
```

```
##
##
##    Cell Contents
## |-------------------------|
## |                       N |
## |           N / Row Total |
## |           N / Col Total |
## |         N / Table Total |
## |-------------------------|
##
##
## Total Observations in Table:  6490
##
##
##                | prediccion.knn.150
## etiquetasTest |         1 |         2 | Row Total |
## --------------|-----------|-----------|-----------|
##             1 |      3116 |       138 |      3254 |
##               |     0.958 |     0.042 |     0.501 |
##               |     0.950 |     0.043 |           |
##               |     0.480 |     0.021 |           |
## --------------|-----------|-----------|-----------|
##             2 |       163 |      3073 |      3236 |
##               |     0.050 |     0.950 |     0.499 |
##               |     0.050 |     0.957 |           |
##               |     0.025 |     0.473 |           |
```

```
## --------------|-----------|-----------|-----------|
##  Column Total |      3279 |      3211 |      6490 |
##               |     0.505 |     0.495 |           |
## --------------|-----------|-----------|-----------|
##
##
```

K = 350

```
prediccion.knn.350 <- knn(train = conjuntoEntrenamiento,
                          test = conjuntoTest,
                          cl = etiquetasEntrenamiento,
                          prob = TRUE,
                          k = 350)
head(prediccion.knn.350)
```

```
## [1] 2 2 1 1 1 2
## Levels: 1 2
```

Sacamos crosstable:

```
CrossTable(x = etiquetasTest ,
           y = prediccion.knn.350,
           prop.chisq = FALSE)
```

```
##
##
##    Cell Contents
## |-------------------------|
## |                       N |
## |           N / Row Total |
## |           N / Col Total |
## |         N / Table Total |
## |-------------------------|
##
##
## Total Observations in Table:  6490
##
##
##                | prediccion.knn.350
## etiquetasTest |         1 |         2 | Row Total |
## --------------|-----------|-----------|-----------|
##             1 |      3104 |       150 |      3254 |
##               |     0.954 |     0.046 |     0.501 |
##               |     0.942 |     0.047 |           |
##               |     0.478 |     0.023 |           |
## --------------|-----------|-----------|-----------|
##             2 |       191 |      3045 |      3236 |
##               |     0.059 |     0.941 |     0.499 |
##               |     0.058 |     0.953 |           |
##               |     0.029 |     0.469 |           |
## --------------|-----------|-----------|-----------|
```

```
##  Column Total |      3295 |      3195 |      6490 |
##               |     0.508 |     0.492 |           |
## --------------|-----------|-----------|-----------|
##
##
```

Random Forest

Random Forest es otro algoritmo supervisado que se basa en la creación de árboles de decisión, en los cuales se hacen preguntas y según la contestación obtenemos un resultado u otro. Finalmente, todos los bosques que se forman llegan a un acuerdo y se pone la decisión final.

Para el random forest no se necesita por su naturaleza un centrado y escalado anterior, de tal manera que directamente procedo con la parte de estadísticas del dataframe original:

```
data.ml.rf <-  data.ml[, 1:18]
data.ml.rf <- data.ml.rf[, -2] # Me quedo solo con la parte de stats y
sin el ganador

model <- randomForest(as.factor(data.ml[, 2]) ~ ., data = data.ml.rf,
importance = TRUE, ntree = 300)
model

##
## Call:
##  randomForest(formula = as.factor(data.ml[, 2]) ~ ., data =
data.ml.rf,      importance = TRUE, ntree = 300)
##                Type of random forest: classification
##                      Number of trees: 300
## No. of variables tried at each split: 4
##
##         OOB estimate of  error rate: 2.81%
## Confusion matrix:
##       1     2 class.error
## 1 25463   614  0.02354565
## 2   835 24578  0.03285720
```

Aquí podemos ver la matriz de confusión, de la que obtenemos también el fallo por clases.

El Out-Of-Bag es un método de estimación de error que se usa en algunos algoritmos como Random Forest, y usa el modelo de Bagging para hacer muestras de submuestras usadas para el entrenamiento. El OOB es el error de predidcción medio de cada una de las muestras de entrenamiento.

Bagging es un meta-algoritmo usado para aumentar la estabilidad y precisión de algoritmos de Machine Learning de clasificación y regresión.

Ahora obtenemos el número de árboles que necesitamos realmente, y la importancia de las variables en este modelo:

```
plot(model, main="Random Forest - Solo Stats")
```

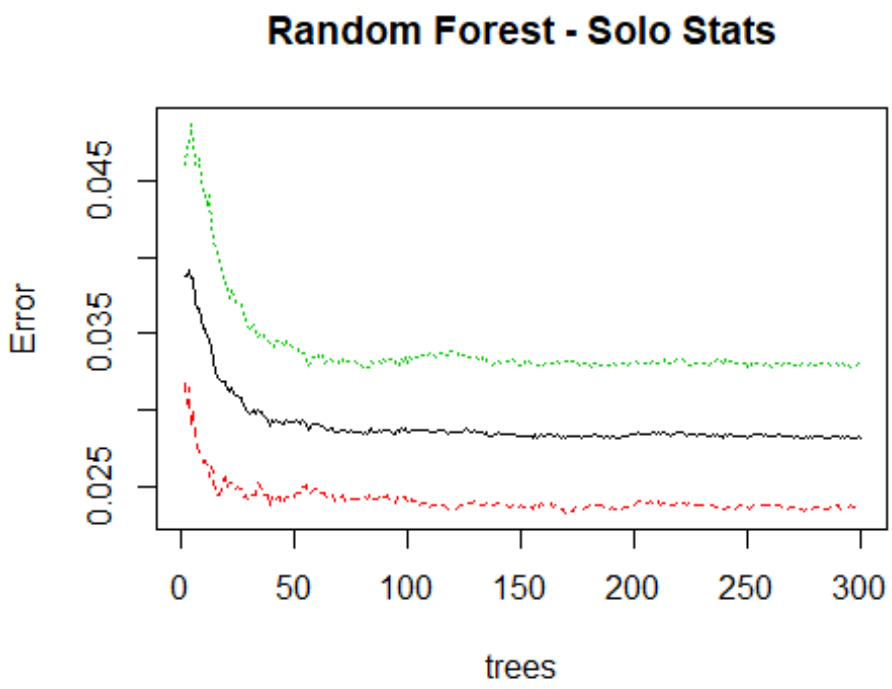


```
varImpPlot(model, main = "Random Forest (Stats) - MDA y Gini") # Gracias
a importance = true
```

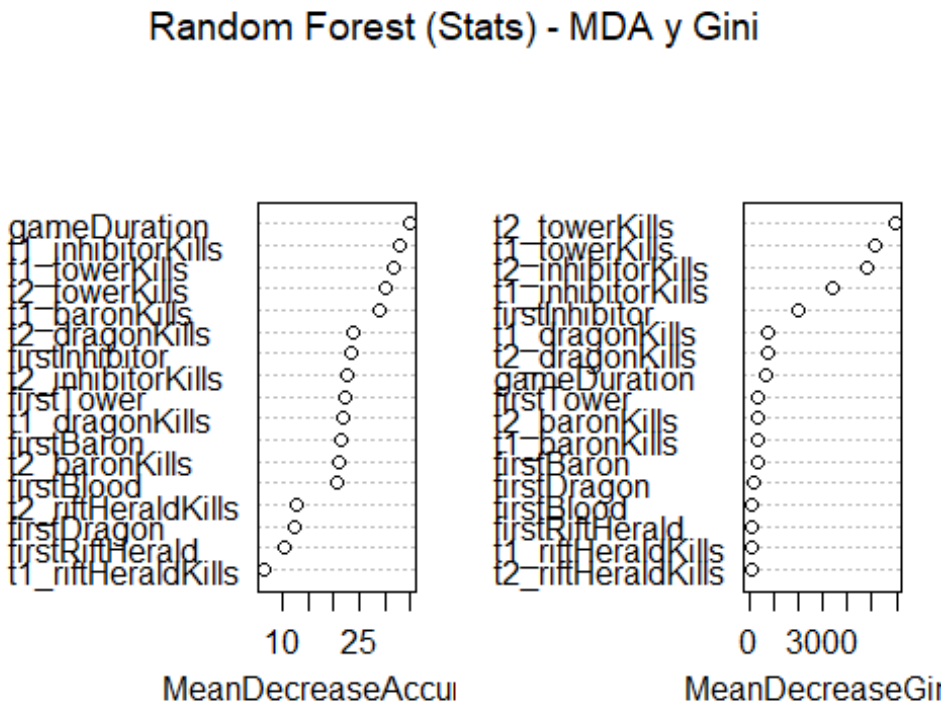

Lo exportamos a PDF...

```
pdf("../imagenes/RandomForest_FT.pdf")
plot(model, main="Random Forest - Solo Stats")
varImpPlot(model, main = "Random Forest (Stats) - MDA y Gini")
dev.off
```

```
## function (which = dev.cur())
## {
##     if (which == 1)
##         stop("cannot shut down device 1 (the null device)")
##     .External(C_devoff, as.integer(which))
##     dev.cur()
## }
## <bytecode: 0x00000000134d26f0>
## <environment: namespace:grDevices>
```

Vamos a interpretar estos datos del modelo:

- MeanDecreaseAccuracy se refiere al decremento de la exactitud del modelo si se permutan los valores en cada característica. En otras palabras, MDA nos muestra la media de valores que se clasificarían mal si se quitara esa característica de la predicción. Los valores que nos da MDA son la media de las variables que no se clasificarían bien en caso de quitar esas variables del entrenamiento del modelo. En nuestro caso, game duration, los inhibidores y las torres son lo que más información le está aportando al modelo.

- MeanDecreaseGini se refiere a la medida de la ganancia media de pureza mediante la división de cierta variable. Cuanto más importante sea la variable, habrá un mayor descenso en el Gini. La importancia de este está íntimamente relacionada a la función de decisión local, que Random Forest usa para seleccionar cual es la mejor separación. Como vemos, las torres y los inhibidores vuelven a ser cruciales para determinar quién es el ganador de la partida.

Ahora lo voy a hacer con 10 fold X Validation:

```
result <- rfcv(data.ml.rf, as.factor(data.ml[, 2]), cv.fold=10)
#head(result)
```

SVM Kernel Lineal

SVM es una técnica supervisada que es muy robusta frente a la dimensionalidad. En este caso, nuestro problema no tiene una dimensión excesiva, pero Vamos a usar esta técnica para ver qué resultados nos arroja. En este caso, con Kernel Lineal:

```
modelo.svm <- svm(data.ml.stats.centscal, as.factor(data.ml[, 2]), kernel
= "linear") # Al poner los grupos como factor, estoy consiguiendo que no
sean continuos para el modelo, sino "discretos", ya que los factor no son
valores que puedan ser continuos. Con esto consigo una clasificación.
summary(modelo.svm)

##
## Call:
## svm.default(x = data.ml.stats.centscal, y = as.factor(data.ml[, 2]),
kernel = "linear")
##
##
## Parameters:
##    SVM-Type:  C-classification
##  SVM-Kernel:  linear
##        cost:  1
##       gamma:  0.05882353
##
## Number of Support Vectors:  4818
##
##  ( 2407 2411 )
##
##
## Number of Classes:  2
##
## Levels:
##  1 2
```

Ahora que tenemos creado este primer modelo, toca predecir:

```
prediccion <- predict(modelo.svm, data.ml.stats.centscal)
head(prediccion)
```

```
## 1 2 3 4 5 6
## 1 1 1 1 1 1
## Levels: 1 2
```

Ahora que hemos predicho, tenemos que sacar la matriz de confusión:

```
matriz.conf <- table(prediccion, data.ml[, 2])
matriz.conf

##
## prediccion     1     2
##          1 25038   945
##          2  1039 24468

sum(diag(matriz.conf))/nrow(data.ml)

## [1] 0.9614682
```

SVM Kernel Radial

Ahora vamos a probar SVM pero con Kernel Radial:

```
modelo_svm.radial <- svm(data.ml.stats.centscal, as.factor(data.ml[, 2]),
kernel="radial")
summary(modelo_svm.radial)

##
## Call:
## svm.default(x = data.ml.stats.centscal, y = as.factor(data.ml[, 2]),
kernel = "radial")
##
##
## Parameters:
##    SVM-Type:  C-classification
##  SVM-Kernel:  radial
##        cost:  1
##       gamma:  0.05882353
##
## Number of Support Vectors:  4273
##
##  ( 2135 2138 )
##
##
## Number of Classes:  2
##
## Levels:
##  1 2
```

Aquí tenemos una C-Classification (necesaria para clasificar), con Kernel esta vez radial.

Ahora que tenemos creado este segundo modelo, toca predecir:

```
prediccion.radial <- predict(modelo_svm.radial, data.ml.stats.centscal)
head(prediccion.radial)

## 1 2 3 4 5 6
## 1 1 1 1 1 1
## Levels: 1 2
```

Ahora que hemos predicho, tenemos que sacar la matriz de confusión:

```
matriz.conf.radial <- table(prediccion.radial, data.ml[, 2])
matriz.conf.radial

##
## prediccion.radial     1     2
##                 1 25527   798
##                 2   550 24615

sum(diag(matriz.conf.radial))/nrow(data.ml)

## [1] 0.9738202
```

Epílogo Modelos Supervisados

Como hemos visto, solo con la parte de estadísticas podemos obtener una predicción de los resultados bastante acertada. Los otros dos dataframes que he creado (champions y total) tendríamos que probarlos ante los mismos métodos, pero el problema es que son demasiado grandes como para ejecutarlos en un ordenador de una manera medianamente rápida (según mis cálculos, en mi portátil son más de 2 días de computación contínua). De este modo, queda aquí indicado que la prueba de ellos (especialmente el de sólo campeones) sería una buena muestra de ver si se puede predecir el resultado de la partida sin las estadísticas principales.

Algoritmos no supervisados

Como podemos ver, los datos de ninguna manera son perfectamente separables, sino que las partidas que gana el equipo 1 se centran más a la izquierda en esta componente discriminante que forma x, y las del dos se centran más a la derecha. Como podemos ver, está bastante difuminada la frontera.

Cluster Jerárquico

En este caso, el cluster lo haré con un número reducido de partidas, ya que si no el cluster no se verá demasiado bien:

```
#Usamos la matriz de centrado y escalado para que cada coordenada
represente el mismo grado de diferencia

d <- dist(data.ml.stats.centscal[1:60, ], method = "euclidean")

cluster.jerarquico <- hclust(d, method = "complete" )
```

```
plot(cluster.jerarquico, cex = 0.5, hang = -1, main="Dendrograma 75
primeras partidas")
```

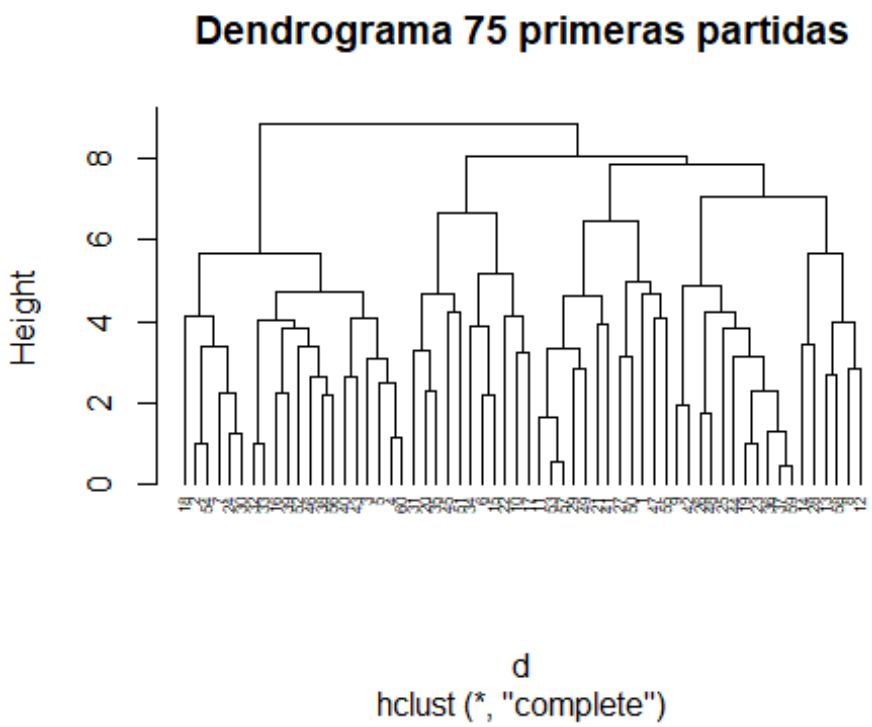

Exportamos a PDF...

```
pdf("../imagenes/clusterJerárquico.pdf")

plot(cluster.jerarquico, cex = 0.5, hang = -1, main="Dendrograma 60
primeras partidas")

dev.off()

## png
##   2
```